

中山大學

SUN YAT-SEN UNIVERSITY

数字图像处理实验报告

基于颜色空间与双眼双椭圆先验的人脸分割（Lab3 & Lab4）

姓 名 _____

学 号 _____

学 院 _____

专 业 _____

2026 年 11 月 8 日

摘　要

本报告系统研究基于颜色统计与几何形态学先验的人脸区域分割，涵盖实验三（基础颜色分割与形态学补全）与实验四（双眼定位引导的双椭圆空间约束及低支持度重建）两个阶段。实验使用 162 张带像素级标签的 512×512 图像，按 98/32/32 固定划分为训练集、验证集与测试集。在实验三中，训练集提取皮肤与鼻子像素估计 YCrCb 空间 Cr/Cb 均值与标准差；独立测试表明，$k = 1.25$ 矩形阈值配合最大连通域与填孔取得全局 F1 70.69%、IoU 54.67%，比纯阈值基线提高 8.03 和 9.04 个百分点。针对面部开口尝试的 41×41 膨胀—填孔—腐蚀补全虽将召回率提高 4.00 个百分点，但精确率下降 2.80 个百分点，F1（70.70%）几乎不变，说明无空间锚点的形态学只能在等值线上移动工作点，无法解决“最大连通域误删碎裂面部”与“头发脖颈粘连扩张”的矛盾。

实验四针对上述瓶颈引入五官位置与椭圆形状先验。首先通过分阶段连通域诊断和直接肤色轮廓拟合实验，证实待修整肤色轮廓本身易受粘连头发或局部碎片带偏；进而利用灰度黑帽变换结合训练集双窗空间先验定位双眼（验证集定位合格率达 28/32，配合严格/放宽两级面积比回退覆盖 31/32 张图，无配对样本安全回退 Lab3），由双眼中心、间距与倾角推算正中及左右侧向偏移（± 0.16 倍眼距）的人脸基础椭圆，并构造内外嵌套双椭圆（缩放系数 0.82 与 1.20）：外椭圆截断越界的头发、脖颈与背景粘连，过渡区采用 5×5 弱闭运算保留边缘，内椭圆采用 11×11 强闭运算与填孔修复核心区；针对内椭圆支持率低于 0.18 的严重漏检样本，在内椭圆内将肤色阈值放宽至 $k = 2.00$ 重选并以 27×27 闭运算与核心种子连通锚定完成受限重建。在 32 张验证集上，实验四将全局 Precision 从 64.86% 提升至 79.88%，Recall 从 82.70% 提升至 86.15%，全局 F1 从 72.70% 跃升至 82.89%（+10.19 个百分点），IoU 从 57.11% 提升至 70.79%（+13.68 个百分点），实现了精确率与召回率的同步突破。

关键词：人脸分割；YCbCr 肤色模型；黑帽变换；双眼定位；嵌套双椭圆先验；形态学重建

目录

1 问题与路线 **1**

1.1 任务与边界 1

1.2 三个问题 1

1.3 证据状态与章节安排 1

2 数据与评价口径 **2**

2.1 数据来源与筛选 2

2.2 划分与泄漏检查 2

2.3 两套标签：建模用皮肤，评价用整脸 2

2.4 指标：为什么不能只看 Accuracy 3

3 颜色模型与初版方案 **4**

3.1 颜色空间与丢弃 Y 的代价 4

3.2 训练肤色统计 5

3.3 判决规则与验证选参 6

3.4 设计取舍 8

4 初版方案的独立测试 **8**

4.1 测试设置 8

4.2 总体结果 9

4.3 提升来自哪一步 10

4.4 误检从哪里来 10

4.5 逐图稳定性与亮度条件 11

4.6 三类失败 13

5 补全尝试与再次评价 **14**

5.1 从失败分析到可检验的假设 14

5.2 补全流程与核的选择 15

5.3 验证集上的取舍 16

5.4 同一批测试图上的再次评价 16

5.5 收益与代价的图像对照 17

5.6 这次尝试改变了什么，没有改变什么 20

6 颜色模型的能力边界与适用范围 **21**

6.1 方法的实际构成 21

6.2 三个工作点 21

6.3 有效性的来源 22
6.4 失效的来源 23
6.5 适用条件 24
6.6 与其他颜色方法的关系 25
6.7 小结 26

7 实验四：双眼引导的双椭圆约束与低支持重建 26
7.1 从最大连通域诊断到直接轮廓拟合的局限 26
7.2 双眼位置识别：灰度黑帽变换与双窗空间先验 28
7.3 双椭圆空间约束与侧向姿态候选 31
7.4 低支持度放宽肤色阈值重选与分区形态学连接 32
7.5 验证集消融实验与整体指标提升 34
7.6 典型案例分析与方法边界 35

8 结论与反思 38

1 问题与路线

1.1 任务与边界

课程要求在一个颜色空间内对亚洲人脸进行分割，并对多幅人脸图像验证。我们把它落实为像素级的人脸区域分割：输入一张 512×512 的彩色图像，输出与原图同尺寸的二值掩膜，1 表示脸部，0 表示其他。评价的正类包括皮肤、鼻子、双眼、双眉、口腔和上下唇；眼镜作为忽略区域，不参加任何混淆计数。

有两个边界需要先说明。第一，肤色掩膜不等于人脸检测，更不等于身份识别。掩膜可能包含脖子、耳朵等皮肤区域，也不保证画面中只有一张脸；本报告不评价识别性能。第二，数据中的“亚洲人脸”来自实验者的外观筛选，没有官方人群属性标签；报告中的结论只对应这批图像及其固定划分，不外推到“所有亚洲人脸”。

1.2 三个问题

全文围绕三个问题展开。第一，这批人脸的肤色在 Cr/Cb 上是否足够集中，均值与标准差能否概括？第二，只靠颜色加两个空间规则，F1 能做到多少，提升来自哪一步？第三，它在什么图像条件下还成立，失败是参数问题还是模型问题？

对应地，我们经历了两个实验阶段的递进探索。实验三围绕纯颜色与基础连通域规则做了三次判断：第一次是颜色范围（k 取多少），第二次是空间结构（最大连通域与填孔值多少），第三次是无约束补全强度（在填孔前加入 41×41 膨胀、填孔后再腐蚀能否补回内部缺口）。实验四则针对实验三暴露的“过早取最大连通域误删脸部碎片”与“头发脖颈粘连无法靠无约束形态学分离”两类核心瓶颈，引入基于灰度黑帽变换与双窗先验的双眼位置识别，由双眼几何关系生成正中与侧向内外嵌套双椭圆，结合低支持度样本放宽肤色阈值（$k = 2.00$）重选及分区形态学连接，突破了纯颜色模型的等值线限制。

1.3 证据状态与章节安排

初版方案在固定配置后只运行一次测试，得到本报告唯一的独立测试结果。实验三的 41×41 补全尝试来自测试图 00570 的误差，因此在同一批测试图上的数字按开发后再评价报告；实验四的双眼定位与双椭圆约束形态学优化则严格固定在 32 张验证集（开发集）上进行多轮消融与验证，各阶段结果在表与图中均明确标注所属集合与证据状态，不相互混用。

第 2 章说明数据、标签与评价口径；第 3 章给出颜色模型与实验三初版方案；第 4 章报告独立测试并归纳三类失败；第 5 章接第三类失败，做无约束形态学补全尝试并再次评价；第 6 章讨论纯颜色模型的能力边界与适用范围；第 7 章系统报告实验四的双眼定位、双椭圆空间约束、侧向椭圆候选、低支持放宽阈值重建与分区形态学连接优化；第 8 章总结全文。

在独立测试集上，实验三初版 F1 为 70.69%，41×41 补全后为 70.70%，说明无空间锚点的形态学只能改变召回与精确率的分配；而在验证集上，实验四将全局 F1 从实

验三的 72.70% 大幅提升至 82.89%（IoU 从 57.11% 提升至 70.79%），证明引入五官位置与双椭圆几何先验能够实质性跨越纯颜色分割的性能瓶颈。

2 数据与评价口径

2.1 数据来源与筛选

实验使用 Face_segment 数据及其原始多类别像素标签。原始目录并不按人群属性严格划分；我们以外观接近亚洲人脸为目标，从 `test/real_image/2` 中人工筛选，保留对应标签。最初选入 163 对图像与标签；程序核对配对、尺寸与标签取值时发现 00583 与 00584 的图像文件完全相同、标签不同，按人工决定保留 00583、排除 00584，最终得到 162 对。原图均为 512 × 512 的 RGB 图像，标签为单通道类别图，保留 0–18 共 19 个类别。

数据核查包括原图、彩色标签和半透明叠加图的逐张浏览，没有发现明显的配对或标注问题。这一结论不等于逐像素标注准确性的保证；它只说明数据可以进入后续实验。

2.2 划分与泄漏检查

划分按样本编号排序后用固定种子 42 打乱，得到训练 98、验证 32、测试 32。划分前用 64 位 dHash、汉明距离不超过 8 筛出 35 对相似候选，逐对查看后未发现明显的同照片裁剪或缩放；本次没有核验人物身份，因此这是图像级划分，不声称人物互斥。原数据集目录名 `test` 只是来源信息，本实验在筛选子集内部重新划分。

2.3 两套标签：建模用皮肤，评价用整脸

本实验区分两个区域。肤色建模只用皮肤和鼻子；评价完整脸部时，正类还包括双眼、双眉、口腔和上下唇。眼镜忽略，其余类别为负类。表 1 给出完整映射。

表 1: 原始标签在颜色统计与脸部评价中的用途

用途	标签编号	对应区域
肤色统计	1、2	皮肤、鼻子
脸部评价正类	1、2、4–7、10–12	皮肤、鼻子、双眼、双眉、口腔、上下唇
评价忽略区域	3	眼镜
脸部评价负类	其余类别	背景、双耳、头发、帽子、饰品、脖颈、衣服

这个错位是有意的。眼睛、眉毛和嘴部的颜色不一定接近皮肤；若把它们并入肤色统计，会改变统计对象。但最终目标是完整脸部，所以它们必须计入正类。颜色候选因此天然会在这些位置留下空洞，后面的填孔才有了明确的作用对象。反过来，预测阶段

只能使用原图、训练统计和固定配置，不能读取真值或眼镜位置；忽略规则只在评价时生效。实现上只做一次集合判断，见代码 **2-1**。

代码 2-1　脸部真值与有效区域的生成（dataset.py）

```
POSITIVE_IDS = [1, 2, 4, 5, 6, 7, 10, 11, 12]
IGNORE_IDS = [3]

def binary_labels(labels):
    face = np.isin(labels, POSITIVE_IDS).astype(np.uint8)
    valid = np.logical_not(np.isin(labels, IGNORE_IDS)).astype(np.uint8)
    return face, valid
```

这段代码只做两件事：把皮肤、鼻子和五官合并为脸部正类；把眼镜从有效区域中剔除。`face` 与 `valid` 分开保存，评价时先按 `valid` 选像素，再比较 `face`，所以眼镜像素既不算 TP，也不算 FP。

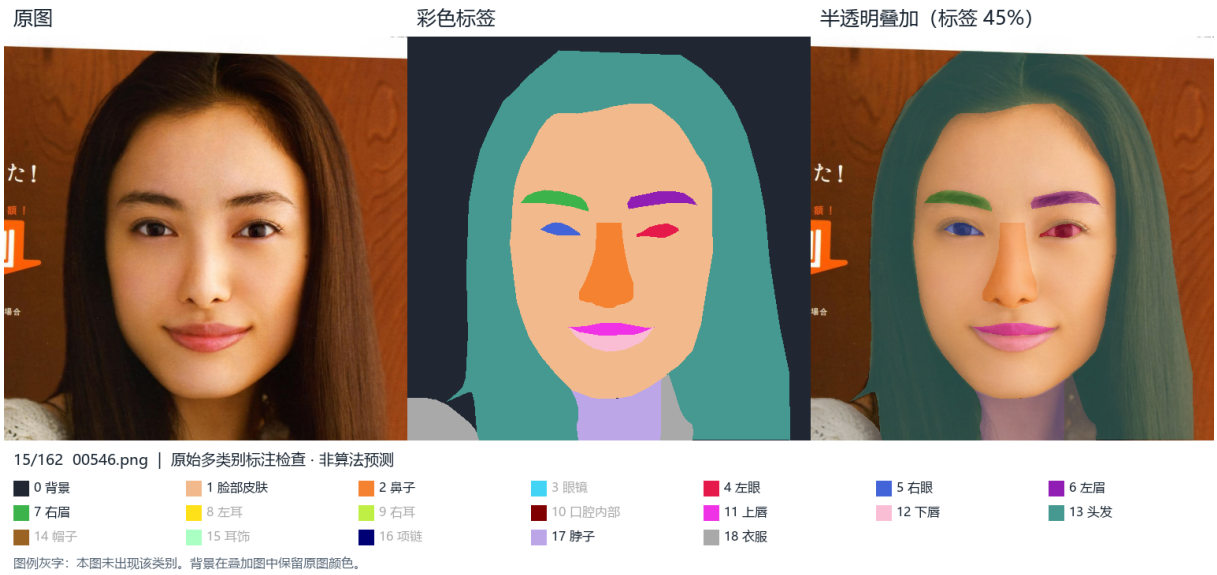


图 1: 样本 00546 的原图、原始多类别标签及叠加核查图。彩色区域来自已有标签，用于检查标注对应关系，并非算法预测。

图 1 展示了原始标签对皮肤、鼻子、眼睛、眉毛和嘴部的区分，也显示头发和脖颈虽与脸部相邻，却属于负类。明确这些边界后，评价才能区分脸部内部缺失与脸部外部误检。

2.4　指标：为什么不能只看 Accuracy

测试集 32 张图共 8,388,608 个有效像素，其中脸部正类 2,150,722 个，占 25.64%。如果把所有像素都判为背景，Accuracy 仍有 74.36%；纯阈值基线的 76.53% 只比这个平凡解高 2.17 个百分点，但它的 F1 是 62.66%。反过来，把所有像素都判为脸部，F1 只有 40.80%。表 2 把这几个参照放在一起。

表 2: 不同预测方式在测试集上的指标对照，单位为百分比

预测方式	Accuracy	Precision	F1
全判为背景	74.36	–	0
全判为脸部	25.64	25.64	40.80
纯阈值基线	76.53	52.91	62.66
初版方案	83.94	66.43	70.69

因此报告以 F1 与 IoU 为主，Precision、Recall 用来解释改善来自哪里，Accuracy 只作补充。多图结果有两种口径：先累加所有图像的 TP/FP/TN/FN 再计算（global），或逐图计算后等权平均（image mean）。前者让脸部面积大的图像占更大权重，后者让每张图权重相同。本报告以 global 为主，逐图平均单独标注，两者不混用。

各指标按式 (1) 计算，所有计数只在有效像素内累加：

$$\begin{aligned} \text{Precision} &= \frac{TP}{TP+FP}, & \text{Recall} &= \frac{TP}{TP+FN}, \\ \text{F1} &= \frac{2TP}{2TP+FP+FN}, & \text{IoU} &= \frac{TP}{TP+FP+FN}. \end{aligned} \tag{1}$$

分母为零时返回空值，而不是 0；全图都被忽略的样本按错误处理，不静默跳过。这样，一张只留下极小块、精确率为 100% 的预测，不会被误当成“完美分割”。

3 颜色模型与初版方案

3.1 颜色空间与丢弃 Y 的代价

YCbCr 把亮度与色度分开。按 ITU-R BT.601，RGB 到 YCbCr 的常用形式为

$$\begin{aligned} Y &= 0.299R + 0.587G + 0.114B, \\ Cr &= 0.713(R-Y) + 128, \\ Cb &= 0.564(B-Y) + 128. \end{aligned} \tag{2}$$

OpenCV 的整数实现与上式略有差异，但通道顺序与含义一致：Y、Cr、Cb，8 位编码 0–255。实现按 BGR 读图，用 `COLOR_BGR2YCrCb` 转换，不做缩放、白平衡或颜色增强。

只用 Cr、Cb 的理由是肤色在色度平面上比在 RGB 中更集中，亮度变化主要落在 Y 上 [1, 2]。代价是丢掉了 Y 中的明暗线索：深色头发和皮肤在色度上可能接近，但在亮度上差别明显。00718 后来正暴露出这一代价；这是当时就知道、但接受了的取舍。

3.2 训练肤色统计

从 98 张训练图取皮肤与鼻子像素，共 $5{,}838{,}561 + 548{,}991 = 6{,}387{,}552$ 个。所有像素等权，不随机抽样，也不先求各图均值再平均；脸部面积大的图像贡献更多像素。对通道 $c \in \{Cr, Cb\}$，均值与总体方差为

$$\mu_c = \frac{1}{N}\sum_{i=1}^{N} c_i, \qquad \sigma_c^2 = \frac{1}{N}\sum_{i=1}^{N}(c_i - \mu_c)^2, \tag{3}$$

其中 $N = 6{,}387{,}552$。计算结果如表 3 上半部分。两通道标准差都约为 9.4，离散尺度接近；这并不表示分类能力相同，因为统计里没有负类。

表 3: 训练肤色统计与阈值覆盖

通道	均值	总体方差	标准差
Cr	151.1495	87.8810	9.3745
Cb	109.1102	89.9380	9.4836

阈值系数 k	1.00	2.00	3.00
范围内训练肤色像素占比	59.17%	91.86%	99.36%

代码 3-1 训练肤色的直方图统计（modeling.py）

```
mask = (labels == 1) | (labels == 2)
ycrcb = cv2.cvtColor(bgr, cv2.COLOR_BGR2YCrCb)
cr = ycrcb[:, :, 1][mask].astype(np.int64)

counts = np.bincount(cr, minlength=256)
n = counts.sum()
values = np.arange(256, dtype=np.float64)
mean = np.dot(values, counts) / n
std = np.sqrt(np.dot((values - mean) ** 2, counts) / n)
```

这段代码先在每张训练图上取皮肤与鼻子像素，累计 256 维直方图，再跨图求和。因为统计对象是直方图而不是逐图像均值，每个像素的权重相同；脸部面积大的图像自然贡献更多像素。方差除以 N 而不是 $N-1$，对应总体方差；σ 由方差开方得到，阈值中使用的是 σ。

联合分布见图 2。高频区域呈倾斜椭圆，按像素频数计算的相关系数约为 -0.7644，协方差为 -67.95：Cr 较大的像素往往对应较小的 Cb。若分别限制两个通道，得到的是轴对齐矩形；它无法贴合倾斜的分布，四角会包含肤色之外的组合，倾斜方向上的肤色又可能被切掉。

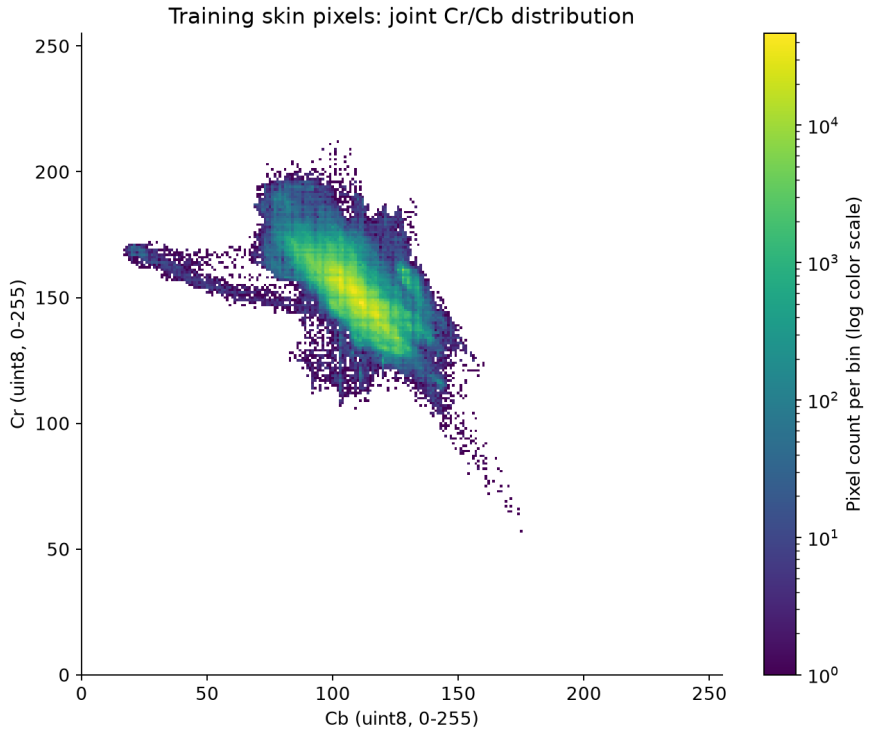


图 2: 训练肤色像素的 Cr/Cb 联合分布。横轴为 Cb，纵轴为 Cr；颜色表示对应整数取值组合的像素数，采用对数刻度。

这个数还有一个用途：估计阈值覆盖了多少训练肤色。表 3 下半部分给出 $k = 1, 2, 3$ 的覆盖比例。$k = 1$ 时矩形只覆盖 59.17%，$k = 2$ 才到 91.86%。也就是说，最终选的 $k = 1.25$ 不是“肤色范围”，而是一个偏精确率的切片：$k = 1$ 时就已经只覆盖 59.17% 的训练肤色，$k = 1.25$ 也远没有覆盖全部。它同时解释了两件事：初版的召回为什么上不去，以及低亮度图像为什么一收紧就掉得厉害。

3.3 判决规则与验证选参

对每个像素，同时满足式 (4) 时记为候选前景：

$$M(x,y) = \begin{cases} 1, & |Cr(x,y) - \mu_{Cr}| \le k\sigma_{Cr} \text{ 且 } |Cb(x,y) - \mu_{Cb}| \le k\sigma_{Cb}, \\ 0, & \text{其他情况.} \end{cases} \tag{4}$$

实现中先转浮点再作差，包含边界；不对每张图像重新估计参数。

颜色候选还需要空间处理。脸部真值包括眼睛、眉毛、口腔与嘴唇，这些位置未必满足肤色范围，容易形成空洞；与脸部分离的类肤色背景则可以通过连通域筛选排除。最终方案先按 8 连通保留面积最大的前景块，再填充不与图像外部背景 4 连通的内部空洞。

代码 3-2 阈值判决与填孔（detection.py）

```
converted = cv2.cvtColor(image_bgr, cv2.COLOR_BGR2YCrCb).astype(np.float64)
cr, cb = converted[:, :, 1], converted[:, :, 2]
mask = ((np.abs(cr - mean_cr) <= k * std_cr) &
```

```
        (np.abs(cb - mean_cb) <= k * std_cb)).astype(np.uint8)

def fill_holes(mask):
    padded = np.pad(mask.astype(np.uint8), 1)
    cv2.floodFill(padded, None, (0, 0), 2, flags=4)
    return (padded[1:-1, 1:-1] != 2).astype(np.uint8)
```

这段代码有两个细节。第一，相减前先转成浮点，避免 `uint8` 回绕；比较使用 `<=`，边界像素算作候选。第二，填孔先在外围补一圈零，再从 `(0,0)` 出发按 4 连通把外部背景标成 2；没有被标到的零像素就是被前景围住的洞，最后统一置 1。补零保证即使目标贴着图像边缘，外部种子仍然有效。

验证集 32 张，比较 9 个 k（1 到 3，步长 0.25）与 4 种处理（无、填孔、最大区域加填孔、闭运算后最大区域加填孔），共 36 组。主指标是全局 F1；平局先选更简单的处理，再选较小的 k。计划在运行前写入配置文件。

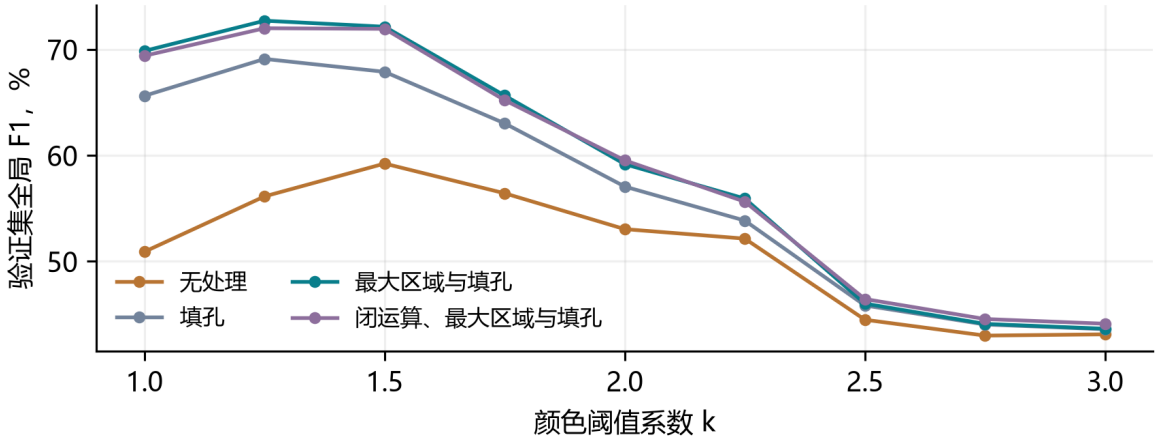


图 3: 四种处理方式在验证集上的参数曲线。横轴为颜色阈值系数 k，纵轴为全局 F1。

图 3 有两个特征。第一，1.25 到 1.5 之间几乎是平台，两者相差不到 0.5 个百分点；最终选 1.25，一部分原因是平局规则，一部分原因是更小的 k 在测试前更保守。第二，k 超过 1.5 后 F1 断崖式下降：颜色范围一放宽，头发和背景就被并进最大连通域，F1 从 72 降到 65、再到 59。失效是结构性的，不是渐进的精度损失。

在相同 $k = 1.25$ 下比较四种后处理，结果如表 4。填孔把 F1 从 56.13 拉到 69.10，是收益最大的一步；最大连通域再加 3.60 个点；闭运算反而低 0.71 个点。我们原本更看好闭运算，觉得它才像“把眉眼补上”，但它在验证集上不如填孔。原因后来在补全实验里才想清楚：闭运算先改变连通性，会把脸和脖子、头发粘在一起，最大区域更容易选错；填孔只填被围住的洞，不动外轮廓。

表 4: 相同颜色阈值下四种后处理的验证结果，单位为百分比

后处理	Precision	Recall	F1	IoU
无处理	52.43	60.39	56.13	39.01
填孔	58.34	84.71	69.10	52.78
最大连通域加填孔	64.86	82.70	72.70	57.11
闭运算后最大区域加填孔	63.39	83.30	71.99	56.24

最终固定 $k = 1.25$、最大连通域加填孔，记为初版方案。它在验证集上的 P/R/F1/IoU 为 64.86/82.70/72.70/57.11。这个配置随后只运行一次测试，结果见第 4 章。

3.4 设计取舍

表 5 列出当时主动放弃的几种做法。它们不是事后补的理由，而是当时的设计边界；第 4 章与第 5 章的失败会逐一回到这些边界上。

表 5: 设计取舍与后来看到的代价

放弃的做法	原因	后来看到的代价
使用 Y 通道	让阈值只管颜色，减少曝光影响	深色头发与皮肤难分（00718）
逐图自适应阈值	保持一个全局模型，避免每图调参	偏色图像无法自救（00609）
椭圆或马氏距离	实现简单、结果可解释	矩形四角包含非肤色；-0.76 的相关性未利用
深度分割模型	课程目标与可解释性	语义鸿沟只能靠后处理绕开
多人处理	数据中没有多人标注	最大连通域只保留一个主体

其中“椭圆或马氏距离”值得多说一句。RGB 规则更简单，但三个通道都混有亮度信息 [3]；椭圆边界不需要更换颜色空间，只需在均值、标准差之外增加一个相关系数，就能利用 -0.76 的联合关系。本实验没有实现它，因此不能给出它可能带来的提升；这里只把它作为由数据直接支持的一个判断记录下来。

4 初版方案的独立测试

4.1 测试设置

测试使用固定划分中的 32 张图，每张 512×512，共 8,388,608 个有效像素。检测只读原图、训练统计和固定配置；评价程序再读取保存的预测，与独立生成的真值对齐。

测试集没有参与选参，也没有在测试后修改配置。当前测试图中没有眼镜像素，忽略逻辑保留但未被触发。

评价只做像素计数，不调用检测函数内部的状态；核心循环见代码 **4-1**。

代码 4-1　有效区域内的混淆计数与指标（evaluation.py）

```
valid = (np.ones(gt.shape, dtype=bool) if valid_mask is None
         else valid_mask.astype(bool))
not_pred, not_gt = np.logical_not(pred), np.logical_not(gt)
tp = np.count_nonzero(pred & gt & valid)
fp = np.count_nonzero(pred & not_gt & valid)
tn = np.count_nonzero(not_pred & not_gt & valid)
fn = np.count_nonzero(not_pred & gt & valid)

precision = tp / (tp + fp) if tp + fp else None
recall    = tp / (tp + fn) if tp + fn else None
f1        = 2 * tp / (2 * tp + fp + fn) if (2 * tp + fp + fn) else None
iou       = tp / (tp + fp + fn) if (tp + fp + fn) else None
```

这段代码用逻辑与同时完成“预测为正”和“真值为正”的筛选：`pred` 是预测掩膜，`gt` 是脸部真值，二者都是 0/1 数组；`valid` 把眼镜像素排除在四个计数之外。分母为零时返回 `None`，不做静默填零。汇总时先把所有图像的 TP/FP/TN/FN 相加再计算 global，逐图平均则单独对每张图的指标做等权平均；两种口径在报告中始终分开标注。

4.2　总体结果

总体指标与混淆计数分别见表 6 和表 7。

表 6: 测试集总体指标，单位为百分比

方案	Precision	Recall	F1	IoU
纯阈值基线	52.91	76.82	62.66	45.63
初版方案	66.43	75.55	70.69	54.67
变化，百分点	+13.52	−1.27	+8.03	+9.04

表 7: 测试集混淆计数

方案	TP	FP	TN	FN
纯阈值基线	1,652,227	1,470,496	4,767,390	498,495
初版方案	1,624,818	821,271	5,416,615	525,904

初版相对基线：F1 提高 8.03 个百分点，IoU 提高 9.04 个百分点；Precision 提高 13.52，Recall 下降 1.27。计数上，FP 减少 649,225，FN 增加 27,409。收益主要来自减少误检，而不是找回漏检。

初版相对基线的变化主要是“删掉不该选的”，而不是“把漏掉的找回来”。召回基本不动，精确率大幅上升；这也解释了为什么初版的 F1 停在 70% 附近——它把颜色候选修剪得更干净，但没有增加新的判别信息。

4.3 提升来自哪一步

把流程拆成四个阶段，可以看到每一步拿什么换什么，结果如表 8。

表 8: 固定流程各阶段的测试结果，指标单位为百分比

阶段	Precision	Recall	F1	FP	FN
基线阈值，$k = 1.50$	52.91	76.82	62.66	1,470,496	498,495
颜色阈值，$k = 1.25$	56.59	65.24	60.61	1,076,315	747,523
保留最大连通域	64.73	63.36	64.04	742,515	787,938
填孔后的结果	66.43	75.55	70.69	821,271	525,904

三步的交换率不同。k 从 1.50 收到 1.25，去掉 394,181 个误检像素，也丢掉 249,028 个正确像素，约合 1 个 TP 换 1.6 个 FP；最大连通域去掉 333,800 个误检，只损失 40,415 个正确像素，约合 1 个 TP 换 8.3 个 FP；填孔补回 262,034 个正确像素，同时增加 78,756 个误检，约合 1 个 FP 换 3.3 个 TP。

单看 k 收紧这一步，F1 从 62.66 降到 60.61，是亏的；它是在给后面的最大连通域让路。最大连通域是最划算的一步；填孔再把内部补回来。三步不能分开评价：阈值、区域和填孔之间存在配合关系，单独调其中一步会得到不同的“最优”。

4.4 误检从哪里来

表 9 把最终误检按原始类别归类，并给出填孔前后两组正类的组内召回。

表 9: 最终误检的语义来源与五官召回

负类	基线 FP	最终 FP	占最终 FP
头发	772,905	497,516	60.58%
脖颈	248,769	192,139	23.40%
背景	369,581	93,639	11.40%
衣服	58,056	20,420	2.49%
双耳	17,665	14,184	1.73%
其他	3,520	3,373	0.41%

正类分组	最大区域后	填孔后
皮肤与鼻子	66.43	76.27
眼、眉、口腔与嘴唇	32.61	68.32

头发和脖颈合计占最终误检的 83.98%。头发容易形成类肤色候选；脖颈则与脸部颜色相近，又常常连在同一前景块上，最大连通域无法把它切开。所以剩余问题不只来自分离的背景，也来自与脸部同色或相连的区域。

其中脖子和耳朵本身是皮肤，这是方法的语义上限。测试集中脖子与双耳合计约 37.4 万像素，而脸部正类约 215 万像素。即使颜色判决完全正确、不再产生任何头发或背景误检，只要结构仍是“最大连通域加填孔”，这部分像素仍会被计入前景，精确率的上限约为 85%。当前精确率 66.43%，离上限还有约 19 个百分点；即使把头发和背景误检全部消除，纯颜色模型也无法达到更高的精确率。这个计算假设所有肤色像素都被判为正类，实际方法可能因连通性排除部分耳朵，因此 85% 是量级上的上限，不是严格界。

填孔确实恢复了五官：眼、眉、口腔与嘴唇的组内召回从 32.61% 提高到 68.32%，补回 69,662 个正确像素；皮肤与鼻子组从 66.43% 提高到 76.27%。方法并不知道那些像素是眼睛或嘴，它只是利用了它们被脸部轮廓包围这一拓扑事实。

4.5 逐图稳定性与亮度条件

逐图指标与亮度分组见表 10。

表 10: 逐图指标、边界质量与亮度分组

统计项目	基线	初版
逐图 F1 平均	0.628	0.681
逐图 F1 中位数	0.664	0.778
逐图 F1 最小值	0.273	0.031
逐图 F1 最大值	0.907	0.930
Boundary IoU 平均	0.153	0.233

亮度分组	图像数	基线 F1	初版 F1
较低	11	56.56	52.82
中间	11	61.90	74.88
较高	10	69.43	83.00

32 张图中有 27 张 F1 提高、5 张下降。中位数从 0.664 升到 0.778，但最小值从 0.273 降到 0.031：多数图像受益，少数图像变差，而且变差得更厉害。逐图 F1 几乎呈两段分布：11 张不低于 0.85，5 张低于 0.2，0.2 到 0.5 之间没有样本。这个形态与“方法依赖一个占主导的肤色连通区域”的解释一致；样本只有 32 张，形态也可能带有偶然性。

按图像配对重采样 10,000 次，总体 F1 差值的 95% 区间为 $+3.57$ 至 $+12.00$ 个百分点；逐图平均 F1 差值的区间为 -0.68 至 $+10.60$ 个百分点。后者跨过 0，说明改善集中在部分图像上；只报一个总体 F1 会掩盖这一点。

按真值脸部平均 Y 排序，把测试图分成 11、11、10 张的较低、中间、较高亮度三组。较低亮度组的 F1 反而从 56.56 降到 52.82，正确像素减少约 9.6 万、漏检增加约 9.6 万；中、高亮度组则分别提高 13 和 13.6 个百分点。低亮度下肤色色度偏离训练分布，$k = 1.25$ 把真肤色也切掉了，减少的误检不足以补偿。需要说明，亮度分组是事后按真值区域平均 Y 划分的，只有 11 张图，且亮度与场景、肤色、妆容混杂；这里只能说明低亮度条件下风险更高，不能把下降单独归因于亮度。

另外采用 Boundary IoU 观察轮廓贴合程度 [4]：使用预测和真值各自的内侧边界带，带宽取图像对角线的 2%（当前为 14 像素），逐图平均后从 0.153 升到 0.233。区域重合改善的同时，边界也有所改善，但 0.233 仍然不高；掩膜看起来完整，边缘并不可信。

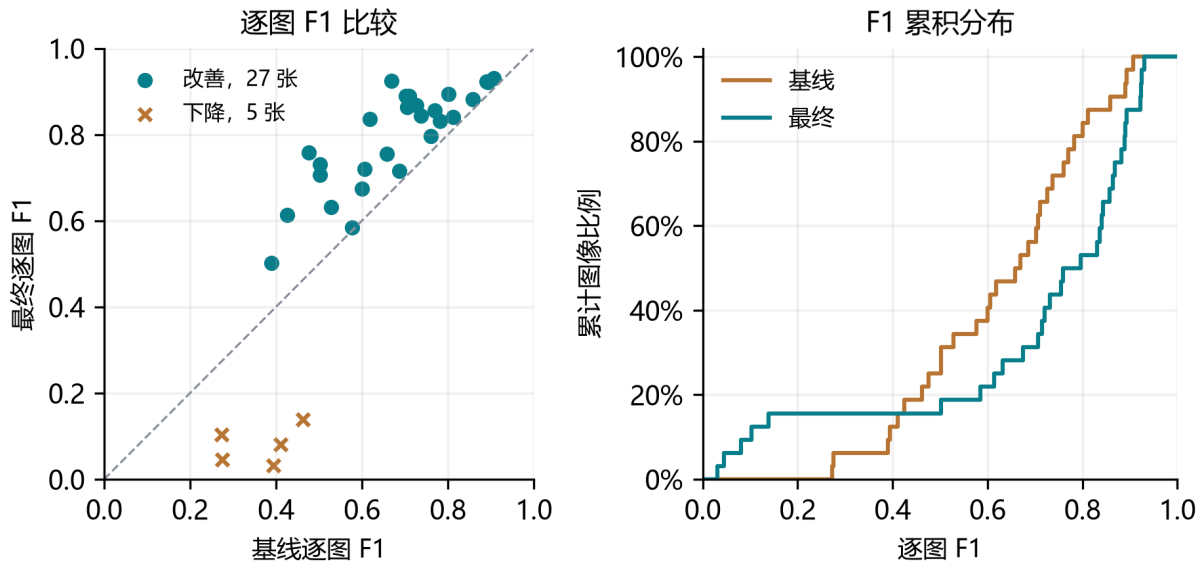


图 4: 逐图 F1 比较与累积分布。左图每个点对应一张测试图，虚线上方表示初版更高；右图为 F1 累积分布。

图 4 同时给出逐图变化和低分尾部。5 张退步图中，有 3 张的 Precision 是 100%——00609、00583、00735 的召回分别只有 1.6%、4.2%、7.4%。掩膜里留下的像素确实都在脸上，但整张脸几乎没被找到。只看“干不干净”，它们接近满分；按 F1 算，它们和全黑没有本质区别。

4.6 三类失败

把 32 张误差图逐张看过去，失败可以归成三类。

第一类是颜色候选不足。00609 在 $k = 1.25$ 下只剩 5,685 个候选像素，分成 56 个连通块，最大块 1,063 像素；最终召回 1.6%，F1 0.031。图像整体偏冷，肤色被推到训练范围之外；错误在颜色阶段就发生了，后面的区域选择和填孔只是没能救回来。

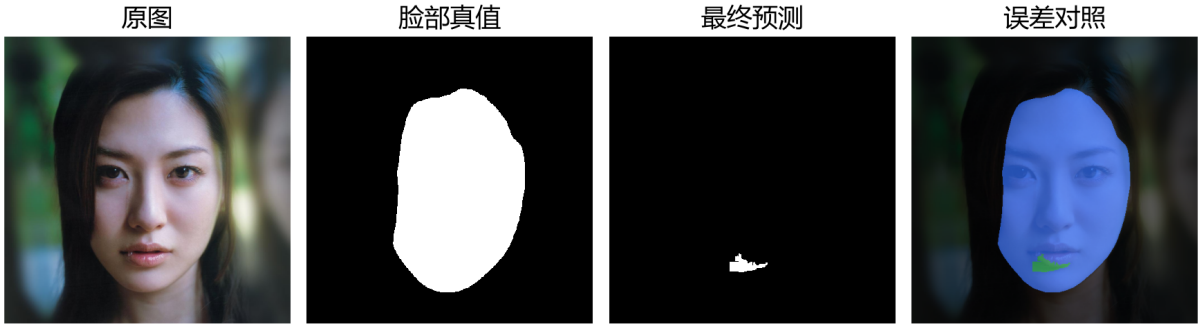


图 5: 00609 的原图、真值、初版预测与误差对照。颜色候选不足导致大面积漏检。

第二类是区域选择错误。00718 中，棕色头发形成 58,716 像素的最大连通块，其中正确像素只有 2,705 个；填孔又增加 110 个正确像素和 10,871 个误检像素，最终 F1 0.045。面积只能表示区域大小，不能表示区域属于什么。

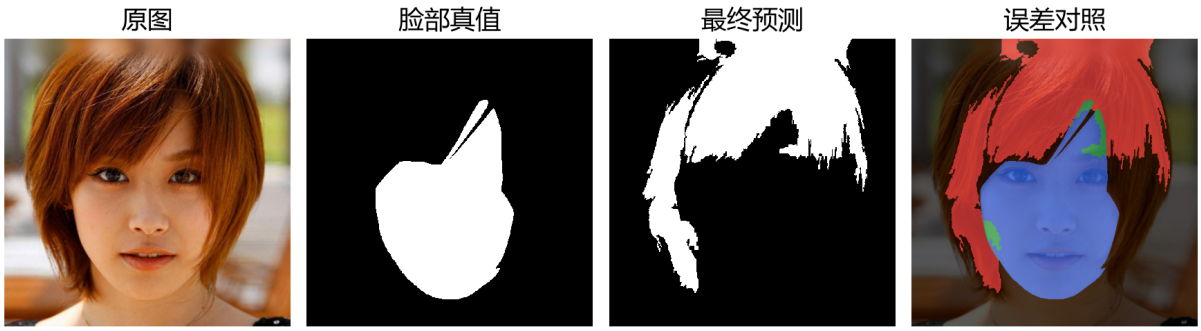


图 6: 00718 的原图、真值、初版预测与误差对照。头发被选为主要候选，填孔扩大了误检。

第三类不同：主体大致正确，但眼睛、嘴部与外部背景连通，填孔补不回来。00570 是一个清楚的例子，嘴部有一条横向缺口；它的 F1 是 0.759，召回 0.631，主要缺失不是“选错”，而是“补不上”。前两类属于颜色与区域的边界，在现有框架内没有便宜的修法；第三类只涉及“如何把开口封住”，可以单独做一次实验。下一章从这里开始。

5　补全尝试与再次评价

第 4 章的失败可以归成三类：颜色候选不足、区域选择错误、主体正确但内部缺口与外部连通。前两类在现有框架内没有便宜的修法——放宽 k 会把头发和背景一起放进来，换区域评分则要引入新的形状假设。第三类不同，它只涉及“如何把开口封住”，可以在不改颜色规则的前提下单独做一次实验。

00570 是一个清楚的例子。初版在 $k = 1.25$ 下得到 68,205 个候选像素，最大连通域保留 27,687 个，填孔后为 37,867 个；F1 为 0.759，召回率为 0.631。误差图上最显眼的是嘴部的一条横向缺口：它与外部背景连通，按填孔的定义不属于“内部空洞”，所以一直留在掩膜里。额头上方也有较大的缺失，但那一块与外部连通得更宽，不是这次能处理的。

5.1　从失败分析到可检验的假设

如果缺口是窄的，先膨胀可以把开口封住；封住之后，填孔就能把内部区域当成封闭空洞补上；最后腐蚀收回外缘。由此可以预期：召回上升，精确率下降，F1 可能基本不变。这个预期在实验前就可以写下来，后面的结果正好可以用来检验它。

补全的作用范围由最大连通域限制，因此它和“放宽 k”不同：后者会在全图扩大颜色候选，头发和背景会一起进来；前者只在已选中的主体周围封口，针对的是“主体大致正确、只是缺口”的情形。这也是我们选择形态学而不是继续调阈值的原因。

最终采用的顺序是：最大 8 连通域 $\rightarrow$ 41×41 椭圆核膨胀 $\rightarrow$ 填孔 $\rightarrow$ 同核腐蚀。膨胀和腐蚀各执行一次；处理前在图像外围补零，全部步骤结束后再裁回原尺寸，避免有限边界让腐蚀多削掉贴边目标。核的直径按原图像素计，当前数据为 512×512；换分辨率需要重选，不能直接照搬。

闭运算也能封口，但它在填孔之前就把外缘收了回去；如果窄开口在腐蚀后重新打开，填孔仍会把它当作外部背景。把填孔放在膨胀与腐蚀之间，填孔面对的是仍然封闭的轮廓，内部区域才能被补上；最后的腐蚀只收回外缘，不撤销已经填入的内部像素。这是我们在实现前的判断，验证集上的结果与它一致：最终选中的正是这个顺序。

代码 5-1 补全流程的核心步骤（detection.py）

```
count, labels, stats, _ = cv2.connectedComponentsWithStats(mask, connectivity=8)
if count > 1:
    component = 1 + int(np.argmax(stats[1:, cv2.CC_STAT_AREA]))
    mask = (labels == component).astype(np.uint8)

element = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (kernel, kernel))
pad = kernel
padded = np.pad(mask, pad)
padded = cv2.dilate(padded, element, iterations=1, borderValue=0)
padded = fill_holes(padded)
padded = cv2.erode(padded, element, iterations=1, borderValue=0)
return padded[pad:-pad, pad:-pad].astype(np.uint8)
```

这段代码的顺序与设计一致：先选最大连通域，再膨胀，避免被丢弃的小块在膨胀时重新接回主体；随后填孔，此时开口已经被封住；最后用同核腐蚀收回外缘。处理前按核大小补零，所有步骤结束后才裁回原尺寸，这样贴边目标不会因为数组边界被额外削掉。41×41 是当前 512×512 数据上的选择，换分辨率需要重选。

这样得到第二版代码和结果。需要先说明这次尝试的性质：它的方向来自 00570 的测试误差图。测试分数没有参与选核，但测试样例参与了问题定义；因此第二版在同一批测试图上的数字只能算开发后的再评价，不再独立。第 4 章的 70.69% 仍是本报告唯一的独立测试结果；本章的 70.70% 用来回答“补全改变了什么”，不用来回答“方法有多好”。

5.2 补全流程与核的选择

核大小来自验证集上的 15 组候选：纯阈值、初版、旧 5×5 闭运算参考，以及两种补全顺序各自的 $5, 9, 15, 21, 31, 41$ 六种核。第一轮按全局 F1 比较，初版仍是 72.70%，其余候选中没有一组超过它。这个结果本身是有信息的：如果目标只是最高 F1，补全没有存在的理由。

我们随后把目标改成“在 F1 损失不超过 1 个百分点的前提下最大化召回”，因为这次改进的目标就是减少缺口，而不是提高 F1。改动写在第二次运行之前，计划文件也记录了这次尝试参考过 00570；但它发生在看到第一轮结果之后。严格说，验证集被用了两次。这不会让结果失效，但会放大验证集的乐观偏差；我们在报告里保留这个过程，而不是只写最后选中的配置。

新规则下，41×41 被选中。它同时是核网格的上界；在新候选中，核越大召回越高，规则自然会选到最大。41×41 的验证 F1 为 71.98%，比初版低 0.72 个百分点——

这个差距是规则允许的，也是我们主动接受的。换句话说，第二版的分数结构在选核之前就定了：它注定用约 0.7 个点的 F1 换约 3.5 个点的召回。

41 像素约等于图像宽度的 8%。这已经不是一个去噪级别的操作，而是一次大幅度的区域扩张；后面的误检增长，很大程度上来自这个尺度。

5.3 验证集上的取舍

结果如表 11。

表 11: 补全前后的验证结果，单位为百分比

方案	Precision	Recall	F1	IoU
初版	64.86	82.70	72.70	57.11
补全后	61.77	86.22	71.98	56.22
变化，百分点	−3.09	+3.52	−0.72	−0.89

验证集上，补全减少 78,523 个漏检像素（−20.37%），增加 190,636 个误检像素；召回提高 3.52 个百分点，精确率下降 3.09 个百分点。这个交换在方向上符合预期，在幅度上则提醒我们：补全不是没有代价的。它把判决边界向外推，边界内的像素不会自动变成脸。

F1 只下降 0.72 个百分点，而精确率下降了 3.09 个百分点。原因在分母：精确率的分母是预测前景，召回的分母是真实前景；这次新增的误检像素多于恢复的正确像素，所以精确率的下降比召回的上升更显眼。这个关系在测试集上还会出现。

5.4 同一批测试图上的再次评价

结果如表 12。

表 12: 补全前后的测试结果，单位为百分比

方案	Precision	Recall	F1	IoU
初版	66.43	75.55	70.69	54.67
补全后	63.63	79.55	70.70	54.68
变化，百分点	−2.80	+4.00	+0.01	+0.01

测试集上的方向与验证集一致，幅度更大：召回 +4.00，精确率 −2.80，F1 只差 0.01 个百分点。TP 从 1,624,818 增加到 1,710,868（+86,050），FN 从 525,904 降到 439,854（$-86,050$），FP 从 821,271 增加到 977,980（+156,709）。TP 与 FN 正好互补，说明补全没有删掉任何原有前景像素——两版掩膜的差异只有新增，没有删除。

新增的 242,759 个前景像素中，86,050 个是脸（35.45%），156,709 个不是（64.55%）。表 13 给出新增像素的语义来源。

表 13: 新增前景像素的来源

真实区域	新增正确像素	新增误检像素
皮肤与鼻子	68,758	0
眼、眉、口腔与嘴唇	17,292	0
头发	0	116,896
背景	0	20,534
脖颈	0	13,043
其他负类	0	6,236
合计	86,050	156,709

新增误检中头发占 74.59%；新增正确像素中，五官组 17,292 个，使眼、眉、口腔与嘴唇的召回率从 68.32% 提高到 79.11%。

这组数字解释了为什么 F1 不动：补全确实把五官补回来了一些，但每补回 1 个正确像素，就同时带进约 1.8 个错误像素。新增区域的正确率只有 35.45%，接近“把边界向外推一圈”所对应的比例。

逐图看，19 张 F1 提高，13 张下降；逐图平均 F1 从 0.681 升到 0.690，但配对重采样的 95% 区间为 -0.45 至 $+2.66$ 个百分点，跨过 0。总体 F1 差值的区间为 -1.27 至 $+1.66$ 个百分点，同样跨过 0。也就是说，这次改动在总体指标上无法与“没有变化”区分。边界 IoU 的逐图均值从 0.233 降到 0.227，说明区域更连续，轮廓反而更不贴合。

如果只以 F1 为准，这次尝试没有带来提升；如果以召回为准，它达到了目的；如果以边界为准，它是退步的。三个判断都成立，取决于把什么当成目标。

5.5 收益与代价的图像对照

00570 的嘴部横向缺口减少，新增 4,367 个正确像素和 1,247 个误检像素，F1 从 0.759 提高到 0.803，召回率从 0.631 提高到 0.707（图 7）。额头和眼周仍有较大缺失：41×41 的核能封住嘴部这种窄开口，封不住额头那种宽缺口。



图 7: 00570 的初版与补全后预测对照。嘴部缺口减少，额头与眼周仍有漏检。

00537 的补全收益最明显（图 8）。召回率从 52.98% 提高到 99.89%，F1 从 0.584 提高到 0.803，新增 25,174 个正确像素和 11,119 个误检像素。掩膜把脸侧头发和肩部一起包了进来，精确率只有 67.06%。这张图说明补全的收益可以很大，但收益的形式是“把主体轮廓向外扩”，不是“把脸部边界找得更准”。



图 8: 00537 找回最多的脸部像素，同时扩大了脸侧误检。

00578 则是另一种情形（图 9）。初版的最大连通域已经落在头发上；补全沿着这块头发继续扩张，新增 22,692 个误检像素，只恢复 1,505 个正确像素，F1 从 0.103 变为 0.105，召回率从 12.57% 升到 14.36%。掩膜看起来更连续，覆盖的仍然是头发，脸还是漏的。

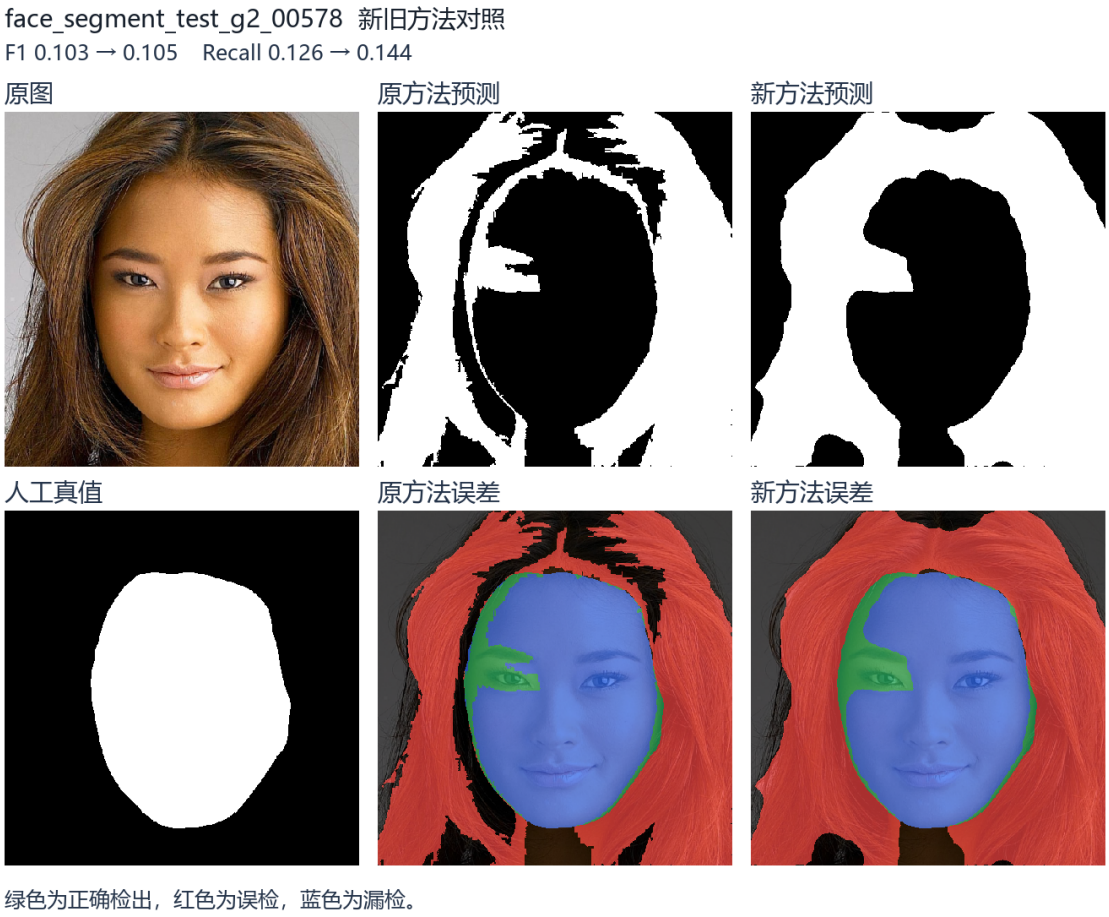


图 9: 00578 中头发误检扩大，脸部主体仍然缺失。

00647 更直接：初版召回已达 99.58%，补全只多恢复 117 个正确像素，却增加 19,907 个误检像素，F1 从 0.720 降到 0.662。对已经接近完整的主体，继续扩张只有代价。

颜色或区域失败的图则几乎没有改善：00609 的召回率从 1.59% 到 1.78%，00718 从 5.12% 到 9.78%。补全只能在候选大致正确时起作用。

5.6 这次尝试改变了什么，没有改变什么

把两次结果放在一起，可以得到一个比 F1 更清楚的判断：补全改变的是覆盖范围，不是判别能力。它把判决边界向外推，被包进来的像素中只有 35% 是脸；它让五官召回提高，也让头发误检增加；它让区域更连续，也让边界 IoU 下降。用一句话说，它把工作点从“偏精确率”移到了“偏召回”，但没有把整条曲线往上抬。

这也解释了为什么 F1 几乎不动：初版和补全后落在同一条 F1 等值线附近（70.69% 与 70.70%），差别只在 P/R 的分配。形态学更像一个工作点参数，而不是一个新的判别模型。

这次尝试仍然是有价值的。它把第 4 章三类失败中的第三类单独拿出来，验证了“缺口可以由拓扑修补部分恢复”这一假设；它也给出了修补的边界：主体大致正确时有效，主体选错时放大错误，颜色候选不足时几乎无效。后两类不是核大小能解决的，它们属于颜色与区域的语义错配。

如果还要往前走，最值得先动的不是核大小，而是让颜色判决知道“这块区域是不是脸”。核大小已经是网格上界，继续加大是否还有收益，本实验没有回答；但 00609 和 00718 的召回只有 1.8% 和 9.8%，说明对这两类失败，核不是主要矛盾。这个问题留到下一章。

最后回到证据边界。如前述，补全后的测试数字是开发后的再评价，不再独立；第 4 章的 70.69% 仍是唯一的独立结果。这个区分不影响本章的机制结论，但影响我们能把 70.70% 写到什么程度。

6　颜色模型的能力边界与适用范围

前五章分别处理了数据、统计、判决、独立测试与补全尝试。本章不引入新的实验，而是回到已经固定的结果，回答一个更基本的问题：这套以 Cr/Cb 阈值为核心的方法，究竟在什么意义上有效，又在什么意义上失效。本章用到的两项统计——F1 分布与精确率上限——均由已保存的逐图像计数和原始类别计数直接算出，没有重新预测，也没有调整参数；它们属于对固定结果的事后解释，不构成新一轮独立测试。

6.1　方法的实际构成

把最终流程拆开，只包含三个判断。第一，像素的 Cr、Cb 是否同时落在以训练均值为中心、以 k 倍标准差为半宽的矩形内；第二，画面中面积最大的 8 连通前景块是否就是脸部；第三，不与图像边界连通的前景空洞是否属于脸部。三者分别对应颜色先验、单主体先验和闭合轮廓先验。补全只是把闭合先验做得更强，没有增加新的判别信息。

这三个先验都不涉及“脸长什么样”。方法没有使用形状、纹理、边缘或五官位置，并在颜色转换后主动丢弃了 Y 通道。因此，我们更愿意把它描述为“肤色检测加两个空间约束”，而不是“人脸分割”。后文对优劣的判断都建立在这一认识上：误差主要不来自阈值是否精细，而来自三个先验在具体图像上是否成立。

这种简化并非疏忽。丢弃 Y 是为了让判决只依赖色度，减少曝光变化的影响；采用最大连通域，是为了在不引入人脸检测器的前提下排除零散干扰；填孔则是为了在不使用五官标签的前提下恢复眼睛、眉毛和嘴部。三项选择都以“不引入额外模型”为代价，换取实现的简单与结果的可解释。这些代价在第 4 章与第 5 章的失败样例中均有体现。

6.2　三个工作点

表 14 把三次判断的结果放在一起。纯阈值是颜色单独作用时的位置；初版加入区域与填孔；补全再加膨胀与腐蚀。

表 14: 三种方案在测试集上的位置与证据状态

方案	Precision	Recall	F1	IoU	证据状态
纯阈值	52.91	76.82	62.66	45.63	独立测试
初版	66.43	75.55	70.69	54.67	独立测试
补全后	63.63	79.55	70.70	54.68	开发后对比

初版把精确率从 52.91 拉到 66.43，召回几乎不动；补全把召回推到 79.55，精确率退回 63.63。初版与补全后落在同一条 F1 等值线附近；基线不在同一条线上，F1 低约 8 个百分点。图 10 把这层关系画了出来。

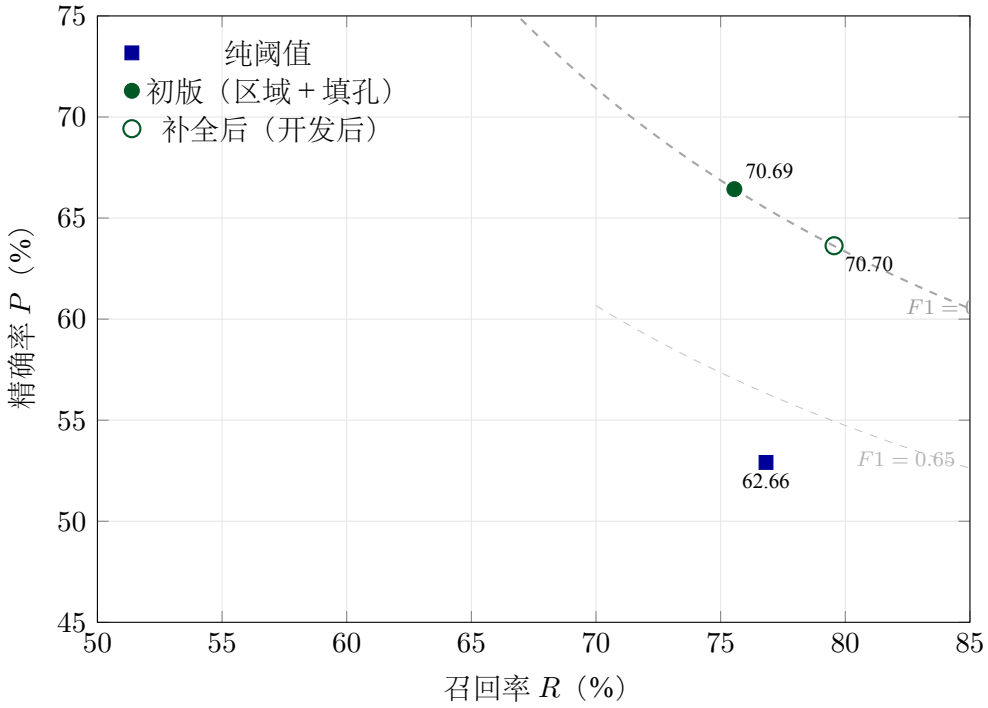


图 10: 三种方案在测试集上的精确率—召回率位置。实心点为独立测试，空心点为开发后对比；虚线为 F1 等值线。

这张图说明，补全没有让模型“更准”，只是把判决边界向外推了一圈：被包进来的像素中只有 35.45% 是脸。初版与补全后之间的选择，不是“哪个方法更好”，而是“愿意用多少精确率换多少召回”。

6.3 有效性的来源

从结果分布看，32 张测试图的初版 F1 并不呈连续分布。不低于 0.85 的有 11 张，其中 4 张超过 0.92；低于 0.2 的有 5 张；0.2 至 0.5 之间没有样本。补全后这个形状基本不变：11 张不低于 0.85，5 张低于 0.2，只有个别图像跨过区间边界。方法在多数图像上表现较好，在少数图像上几乎完全失败，中间状态很少。

在我们看来，这种两段式分布与第 6.1 节的结构假设一致。当脸部构成画面中占主导的肤色连通区域时，三个先验同时成立：颜色候选接近完整，最大连通域不会选错，填孔也能补回被包围的五官。当这一条件不成立时，错误会沿同一条链条被放大，而不是表现为分数的平缓下降。当前样本只有 32 张，这一形态也可能带有偶然性；但它至少提示，方法的成败更接近“条件是否满足”，而非“参数是否精细”。

在满足条件的图像上，方法的表现相当稳定。样本 00610 的原始候选为 80,328 像素，最大连通域保留 79,899 像素，填孔补回 9,490 个正确像素，最终 F1 为 0.930，召回率为 97.7%。00585、00629、00538 等图的情况类似。这些图像的一个共同特征是正面或近正面、脸部占画面比例较大、光照较均匀，头发与背景的颜色和肤色可分。对这些图像，颜色候选本身已接近完整，后处理只需少量修补。

方法的第二个优势体现在对五官的补偿上。颜色规则本来不覆盖眼睛、眉毛和嘴部，但填孔把这一组的召回率从 32.6% 提高到 68.3%，补回 69,662 个正确像素；皮肤与鼻子组也从 66.4% 提高到 76.3%。这说明“脸是一个被肤色包围的连通区域”这一先验在实际图像中相当强。方法并不区分这些像素的语义类别，只是利用了它们被脸部轮廓包围这一拓扑事实。就本实验的目标而言，这一补偿是有效的；但它也解释了补偿的上限：只有被完整包围的区域才能被补回。

第三个优势是可解释与可复现。方法只有四个统计参数和一个整数 k，没有随机初始化，也没有在测试阶段重新估计任何量。每一次失败都可以定位到颜色候选、区域选择或填孔中的某一步：00609 的错误始于颜色候选，00718 的错误始于区域选择，00676 的误差则在填孔阶段被放大。这种可归因性使讨论不必停留在“效果不好”，而可以具体到“哪一条先验没有成立”。此外，方法不需要训练，单张图像只经历一次颜色变换和两次连通域操作，结构上比需要训练的方法轻。

6.4 失效的来源

方法的失效可以按来源分为四类：颜色、空间、语义，以及评价口径。前三类属于方法本身，第四类属于我们如何定义对错。表 15 给出摘要。

表 15: 失效的四类来源

来源	不成立的假设	主要证据	调参能否解决
颜色	肤色落在训练矩形内	00609：候选 5,685 像素、56 块、召回 1.6%；低亮度组 F1 下降 3.8 个百分点	部分缓解，误检会回升
空间	存在占主导的脸部连通块	00718：最大块 58,716 像素，TP 仅 2,705；脖子占误检 23.4%	需更换区域评分
语义	肤色像素都属于脸	脖子与双耳 37.4 万像素；精确率上限约 85%	不能
评价	整脸真值与候选边界一致	逐图 Mask IoU 0.572，Boundary IoU 0.233	不能，属定义问题

颜色层。当图像存在明显偏色或照度不足时，真实肤色的色度会偏离训练分布，$k = 1.25$ 的矩形随之把大量正确像素排除在外。00609 是典型：$k = 1.25$ 下只剩 5,685 个候选像素，分成 56 个连通块，最大块 1,063 像素，最终召回率 1.6%。亮度分组的结果与此一致：较低亮度组的初版 F1 为 52.8%，比基线低 3.8 个百分点，正确像素减少约 9.6 万，漏检增加约 9.6 万。补全对这类图几乎没有作用：00609 的召回只从 1.59% 到 1.78%。需要说明，亮度分组是事后按真值区域平均 Y 划分的，只有 11 张图，且亮度与场景、肤色、妆容混杂，因此这里只能说明低亮度条件下风险更高，不能把下降单独归因于亮度。

空间层。最大连通域假设画面中存在一个占主导地位的脸部候选。当与肤色相近的头发形成更大连通块时，这一假设直接失效。00718 中，棕色头发构成 58,716 像素的最大块，其中正确像素只有 2,705 个，误检 56,011 个；填孔随后又增加 110 个正确像素和 10,871 个误检像素，最终 F1 为 0.045。补全把召回从 5.12% 推到 9.78%，仍然无济于事；00578 中，补全甚至沿着头发继续扩张，新增 22,692 个误检像素。这个例子说明，面积只能表示区域大小，不能表示区域属于什么。类似地，脖子与脸部通常连成同一块，无法通过连通性切开；在最终误检中，头发与脖子合计占 84.0%，其中脖子单独占 23.4%。

语义层。这是方法的真正上限。耳朵和脖子本身也是皮肤，颜色规则没有理由排除它们。测试集中，脖子与双耳合计约 37.4 万像素，占全部有效像素的 4.5%，而脸部正类约 215 万像素。即使颜色判决完全正确、不再产生任何头发或背景误检，只要结构仍是“最大连通域加填孔”，这部分像素仍会被计入前景，精确率的上限约为 85%。当前初版的精确率为 66.4%，与这一上限之间还有约 19 个百分点，说明头发与背景误检仍是主要矛盾；但即使把这些误检全部消除，纯颜色模型也无法达到更高的精确率。这一计算建立在“所有肤色像素都被判为正类”的假设上，实际方法可能因连通性排除部分耳朵，因此 85% 是量级上的上限，而非严格界。它的意义在于指出：剩余误差中有一部分不是参数问题，而是“颜色”这一信息本身不包含“脸”这一语义。

评价口径。还有一层不确定性来自评价本身。整脸真值与颜色候选之间的错位是任务定义的一部分：眼睛、眉毛和嘴部被计入正类，却不参与颜色建模。边界质量也受到这一错位的影响。初版方案的逐图 Mask IoU 平均为 0.572，而 Boundary IoU 平均仅为 0.233；前者说明区域大体重合，后者说明轮廓并不可信。填孔产生的是由外围轮廓决定的平滑边界，而不是真实的发际线或下颌线；标注本身在这些位置也存在歧义。因此，本方法适合给出粗略区域，不适合用于需要精确边缘的场合。

6.5 适用条件

把上述结果整理成条件，可以得到一个相对清晰的适用范围。这些条件来自 32 张测试图的观察，属于经验总结，不是经过独立验证的判据。表 16 给出摘要。

表 16: 适用条件与实验依据

场景条件	实验观察	判断
单人、近正面、脸部占比较大、光照均匀	11 张 F1 不低于 0.85，4 张超过 0.92	适用
偏色或照度不足	00609 F1 为 0.031；低亮度组下降 3.8 个百分点	风险高，需预处理
头发或背景与肤色接近	头发占误检 60.6%；00718 F1 为 0.045	易失效
脸与脖子相连	脖子占误检 23.4%	精度受限
多人、侧脸、遮挡	本数据未覆盖	未验证，不宜外推
需要精确边缘	Boundary IoU 0.233	不适用

据此，我们把适用场景限定为：单人、正面或近正面、脸部在画面中占较大比例、光照较均匀且与背景有较明显色差的图像；任务应是粗粒度区域提取或前置筛选，而不是精确边缘。多人、侧脸、遮挡等情形在本数据中没有覆盖，我们不把它们列入适用范围，也不据此判断方法在那些情形下的表现。概括而言，这套方法是一个在受控条件下可用的肤色先验，其适用范围主要由拍摄条件决定，参数调节只能在其内部微调。

如果必须在初版与补全后之间选一个，判断依据不是 F1，而是任务更在意什么。以 F1 和边界为准，选初版；以覆盖完整为准，选补全后。两者的 F1 相同，差别在精确率与召回的分配；这也是第 5 章反复出现的“工作点”一词的实际含义。

6.6 与其他颜色方法的关系

最后，把本方法放回颜色分割的谱系中，可以更清楚地看出它的位置。

基于 RGB 的规则更简单，但三个通道都混有亮度信息，阈值同时受光照强度与颜色影响；Cr/Cb 把亮度分离出去，代价是丢弃了 Y 中的明暗线索。本实验没有直接比较两者，00609 的结果只能说明色度通道同样会受白平衡影响，不能说明 RGB 规则一定更差。HSV 的色调对光照变化相对稳健，但皮肤通常落在低饱和区域，色调在低饱和时并不稳定。

训练分布本身还提供了另一条线索。Cr 与 Cb 的相关系数约为 -0.76，联合分布呈倾斜的椭圆，而当前判决使用的是轴对齐矩形。矩形的四个角会包含肤色分布之外的取值组合，而倾斜方向上的肤色又可能被矩形的边切掉。若改用马氏距离或椭圆边界，不必更换颜色空间，只需在现有均值、标准差之外增加一个相关系数，把“各通道独立”的假设换成“两通道联合”的假设。就我们看到的分布形态而言，这是改动最小、针对性最直接的一处。本实验没有实现这一方案，因此不能给出它可能带来的提升；这里只把它作为由数据直接支持的一个判断记录下来。

逐图自适应阈值是另一种常见思路。它可以根据每张图的色度分布重新确定范围，对偏色更稳健；但在本任务中，背景中的木质墙面、暖色衣物同样会形成大面积色度聚

集，自适应阈值有可能把这些区域纳入候选，与最大连通域的假设冲突。是否采用，取决于场景中是否存在稳定的肤色参照，而不能只按“能否适应光照”来判断。

至于基于学习的分割方法，它们能够利用形状、纹理和语义信息，理论上可以越过语义层的限制。但这类方法需要标注数据与训练过程，其结果也不再能简单归因到“颜色范围是否合适”。对于本实验提出的问题——颜色本身能走多远——引入学习模型后，这一问题就不再被回答。因此，我们选择在颜色框架内把边界刻画清楚，而不是用更强的模型换取更高的分数。

6.7 小结

本章的结论可以概括为一句话：这套方法的精度上限由它看不见的信息决定，而不是由 k 或核大小决定。颜色先验、单主体先验和闭合轮廓先验在受控条件下同时成立，方法就能达到 0.9 左右；其中任何一条不成立，误差就会沿流程被放大，而不是被后处理吸收。参数调整只能改变三条先验的松紧，不能补上它们缺少的形状与语义。就本实验而言，它的价值主要在于实现代价低、结果可解释、失败可归因，而不在精度上限。

7 实验四：双眼引导的双椭圆约束与低支持重建

第 5 章与第 6 章表明，在单纯依赖 Cr/Cb 颜色阈值与最大连通域的框架下，41×41 无约束形态学补全只能在 $F1 \approx 70.7\%$ 的等值线上移动精确率—召回率工作点，无法突破“颜色与面积不包含人脸几何语义”的瓶颈。为在不引入预训练深度学习检测器的前提下突破这一上限，实验四在实验三的基础上按两个互补方向推进：其一是**尽量合并因阈值收紧或阴影而断裂的脸部碎片**（方向 A），其二是**尽量截断与脸部粘连的头发、脖颈和类肤色背景**（方向 B），并引入人脸椭圆几何先验统领两类操作。

由于 32 张测试图在实验三误差分析与形态学补全阶段已被逐张检视，实验四的全部探索、消融与参数选择均严格固定在 32 张验证集（开发集）上开展，以实验三初版方案在该集合上的表现（Precision 64.86%、Recall 82.70%、全局 F1 72.70%、IoU 57.11%）作为对照基线；验证集人工标签仅在预测掩膜与候选选择完全固定后用于事后评价。

7.1 从最大连通域诊断到直接轮廓拟合的局限

实验三在 $k = 1.25$ 颜色阈值后直接保留最大 8 连通域并填孔。为量化“最大连通域筛选”究竟删去了什么，我们在 32 张验证图上对比了“原始阈值（`raw`）”“仅最大连通域（`largest`）”“跳过最大块直接填孔（`fill_all`）”与“最大块后填孔（`largest_fill`，即 Lab3 初版）”四个阶段，结果见表 17。

表 17: 验证集上最大连通域筛选与填孔的分阶段像素对照，指标单位为百分比

阶段方案	Precision	Recall	全局 F1	IoU	TP 像素数	FP 像素数
原始阈值（$k = 1.25$）	52.43	60.39	56.13	39.01	1,345,567	1,220,918
仅保留最大连通域	59.23	57.61	58.41	41.25	1,283,698	883,679
跳过最大块直接填孔	58.34	84.71	69.10	52.78	1,887,542	1,347,802
最大连通域加填孔（Lab3）	64.86	82.70	72.70	57.11	1,842,674	998,367

数据显示，在填孔前直接取最大连通域虽然去除了 337,239 个非脸误检像素，但也永久删去了 61,869 个真实脸部像素；反之，若跳过最大连通域直接填孔，虽然找回了更多脸部像素（Recall 达 84.71%），却保留了 1,347,802 个误检像素，且在脸部外轮廓未闭合的样本上依然无法靠填孔恢复内部。图 11 展示了验证集困难样本 00562 的分阶段差异：原始阈值下脸部碎裂为额头、鼻梁、嘴唇等互不相连的小块，而外围发际与脖颈构成了最大连通域；取最大连通域后，橙色标出的内脸正确碎片被悉数删去，后续填孔也因轮廓敞开而完全失效（Lab3 F1 仅为 0.1295）。



图 11: 验证图 00562 的最大连通域分阶段诊断。上排右图橙色为最大连通域筛选误删的真实脸部碎片，青色为正确排除的背景；下排显示无论是否保留最大连通域，敞口轮廓均无法靠普通填孔恢复内脸。

基于 Wang 与 Sung[5] 及 Garcia 与 Tziritas[7] 的线索，我们首先尝试直接从肤色候选轮廓拟合人脸椭圆：对原始阈值、5×5 椭圆核闭运算（轻量连接）和 5×5 椭圆核开运算（轻量分离）三种输入，分别提取连通块与近邻组合，调用 OpenCV `fitEllipse` 拟合外轮廓点，并以同心缩放的内椭圆（0.8 倍轴长）做 9×9 闭运算修补、外椭圆（1.15

倍轴长）裁剪外围误检。表 18 给出了 32 张验证图上各来源默认最大候选的一轮修整结果。

表 18: 弱形态学预操作与直接肤色轮廓椭圆修整的验证集对比，单位为百分比

候选来源	外椭圆 F1	修整后 P	修整后 R	修整后 F1	修整后 IoU	相对 Lab3 ΔF1
Lab3 基线（最大块填孔）	–	64.86	82.70	72.70	57.11	0.00
原始阈值轮廓椭圆	60.06	65.66	81.96	72.91	57.37	+0.21
5×5 闭运算轮廓椭圆	59.69	64.71	82.22	72.42	56.77	−0.28
5×5 开运算轮廓椭圆	59.02	65.32	67.76	66.52	49.83	−6.18

这一轮探索给出了明确的否定性结论：第一，5×5 闭运算无法跨过较大尺度的面部阴影断裂，修整后 F1（72.42%）反而略低于 Lab3；第二，5×5 开运算在切断背景细桥的同时严重削弱了原本有用的脸部边缘，导致 Recall 跌至 67.76%、F1 降至 66.52%；第三，直接对肤色轮廓拟合椭圆仅比 Lab3 高 0.21 个百分点，原因在于**当头发或脖颈与脸部粘连时，外轮廓拟合出的椭圆会被错误区域带偏；当脸部严重碎裂时，局部碎片又只能拟合出偏小椭圆**。这说明椭圆的位置、尺度和方向不能依赖待修整的肤色轮廓本身，必须引入独立于肤色连通块的五官定位锚点。

7.2 双眼位置识别：灰度黑帽变换与双窗空间先验

实验三在转换至 YCrCb 后丢弃了亮度通道 Y，导致深色头发与阴影皮肤在色度上难以区分；但从五官结构看，双眼在灰度图 I_{gray} 中呈现稳定的局部暗斑与水平成对几何关系 [1]。受此启发，我们在不使用任何预训练人脸或眼睛检测器的前提下，利用灰度形态学**黑帽变换（Black-Hat Transform）**提取局部暗部响应：

$$R_{\text{bh}}(x,y) = \big((I_{\text{gray}} * G_{3\times3}) \bullet B_{\text{bh}}\big)(x,y) - (I_{\text{gray}} * G_{3\times3})(x,y), \tag{5}$$

其中 $G_{3\times3}$ 为高斯平滑核，$\bullet$ 表示形态学闭运算，B_{bh} 为横向椭圆形结构元素（宽高取粗略面宽尺度 W_s 的 13% 与 7% 并取奇数）。黑帽响应经 $\max(12, T_{\text{Otsu}})$ 阈值化与 1×3 横向闭运算后，按连通域宽高、面积与长宽比 $[0.65, 7.0]$ 筛选暗部候选，再按眼距范围 $[0.18W_s, 0.65W_s]$、连线倾角 $|\theta| \le 25°$ 及左右候选面积比 $r_{\text{area}} = \min(A_L, A_R)/\max(A_L, A_R)$ 进行配对。每对候选的图像视觉基础分 S_{base} 由五项归一化特征加权组成：

$$S_{\text{base}} = 0.25\, S_{\text{align}} + 0.15\, r_{\text{area}} + 0.15\, S_{\text{space}} + 0.25\, S_{\text{resp}} + 0.20\, S_{\text{skin}}, \tag{6}$$

分别衡量水平对齐度 $1 - |\theta|/25°$、双斑面积相近度、间距接近 $0.36W_s$ 的程度、黑帽响应强度均值，以及候选外围环形邻域内的原始肤色支持率。

为检验图像暗部特征与空间先验各自的贡献，我们在 32 张验证图上依次推进了三轮定位实验。训练集 98 张图像中有 97 张包含完整双眼标注（标签 4、5，样本 00615 除外）；仅用这 97 张训练图统计归一化左眼中心 $\boldsymbol{\mu}_L = (0.3778, 0.4769)$、右眼中心 $\boldsymbol{\mu}_R = (0.6198, 0.4756)$。由于训练集实测标准差极小（约 0.005–0.009），我们将两眼标准

差下限放宽至 $\boldsymbol{\sigma}_L = \boldsymbol{\sigma}_R = (0.025, 0.018)$，在第三轮中以 3σ 椭圆窗口（对 512×512 图像半轴约为 38.4×27.6 像素）分别限制左右眼搜索范围，不再依赖可能出错的肤色连通块外接框，并以训练集平均眼距的 2.5 倍作为统一面宽尺度 W_s。记左、右眼候选中心到各自训练均值的标准化平方距离为

$$d_i^2 = \left(\frac{x_i/W - \mu_{i,x}}{\sigma_{i,x}}\right)^2 + \left(\frac{y_i/H - \mu_{i,y}}{\sigma_{i,y}}\right)^2, \qquad i \in \{L, R\}, \tag{7}$$

则双窗位置得分为两眼高斯得分的几何均值 $S_{\text{pos}} = \exp\big(-(d_L^2 + d_R^2)/4\big)$，综合配对得分为

$$S_{\text{pair}} = (1 - w_p) S_{\text{base}} + w_p S_{\text{pos}}, \qquad w_p = 0.65. \tag{8}$$

以标签双眼质心为事后评价参考，定义归一化定位误差 $e = \max\big(\|\hat{\mathbf{p}}_L - \mathbf{p}_L\|_2, \|\hat{\mathbf{p}}_R - \mathbf{p}_R\|_2\big)/\|\mathbf{p}_R - \mathbf{p}_L\|_2$，三轮定位结果及“完全不看图像、直接输出训练均值”的诊断对照汇总于表 19。

表 19: 验证集 32 张图像上的双眼定位准确率演进与均值诊断对照

定位方法	配对数	首选 $e \le 0.15$	首选 $e \le 0.25$	中位误差 e
第一轮：无位置先验（肤色框内搜索）	30/32	13/32（40.6%）	13/32（40.6%）	0.2648
第二轮：双眼中点弱先验（$w_p = 0.20$）	30/32	15/32（46.9%）	15/32（46.9%）	0.1876
第三轮：两眼独立窗口约束（$w_p = 0.65$）	29/32	26/32（81.3%）	28/32（87.5%）	0.0466
诊断对照：仅输出训练集双眼均值	32/32	32/32（100.0%）	32/32（100.0%）	0.0569

表 19 揭示了两个关键事实。第一，无位置先验时，仅靠“水平成对暗部”极易将双眉（如 00590，$e = 0.265$）或发丝空隙（如 00690，$e = 2.749$）排在真实双眼之前；引入两眼独立搜索窗与位置加权后，$e \le 0.25$ 合格率从 40.6% 跃升至 87.5%，中位误差降至 0.0466（见图 12）。第二，诊断对照表明，直接输出训练均值在当前验证集上即可达到 32/32 合格，说明本数据集人像构图高度居中对齐；因此我们必须客观指出，双眼定位的高准确率在很大程度上受益于数据集构图一致性，而非单纯的黑帽算子具备通用人眼识别能力。

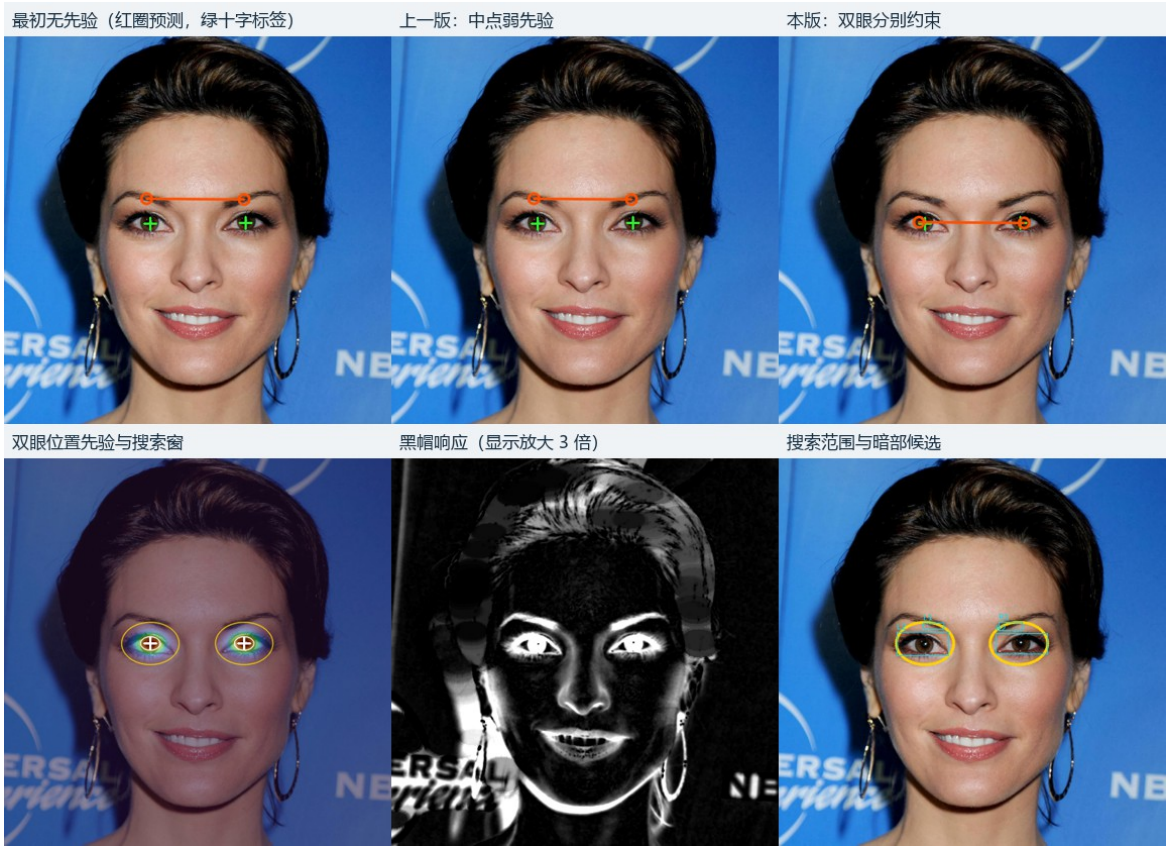


图 12: 验证图 00590 的三版双眼定位对比与中间响应。无先验与中点弱先验均误选双眉（红圈偏离绿十字真值），双窗约束结合灰度黑帽响应准确锁定双眼。

此外，第三轮严格配对规则（$r_{\text{area}} \geq 0.30$）在 00655 与 00690 上因单侧眼部受刘海或阴影影响、左右暗斑面积比约为 0.275 而未能输出配对。为此，我们在最终流程中设计了**严格优先、放宽回退**的两级配对机制（代码 **7-1**）：优先采用 $r_{\text{area}} \geq 0.30$ 的严格配对（`standard_pair`，覆盖 29 张）；仅当严格配对为空时，才回退至 $r_{\text{area}} \geq 0.20$ 的放宽配对（`recovered_pair`，成功找回 00655 与 00690），从而避免低门槛候选覆盖已有的高质量严格配对；若仍无配对（仅 00592 一张），则安全回退至 Lab3 掩膜（`no_pair`），绝不盲目填入训练统计均值。

代码 7-1 双窗黑帽眼睛定位与两级面积比回退（eyes.py, dual_ellipse.py）

```
def choose_eye_pair(strict_pairs, relaxed_pairs):
    if strict_pairs:
        return strict_pairs[0], "standard_pair"
    if relaxed_pairs:
        return relaxed_pairs[0], "recovered_pair"
    return None, "no_pair"

#          3*sigma                          Otsu
d2 = ((xx / w - eye["mean"][0]) / eye["sigma"][0]) ** 2 + \
     ((yy / h - eye["mean"][1]) / eye["sigma"][1]) ** 2
window = d2 <= prior["window_radius_sigma"] ** 2
otsu, _ = cv2.threshold(response[window].reshape(-1, 1), 0, 255,
                        cv2.THRESH_BINARY + cv2.THRESH_OTSU)
```

```
local = ((response > max(config["minimum_response"], otsu)) &
    window).astype(np.uint8)
position = math.exp(-0.25 * (a["prior_distance_squared"] +
    b["prior_distance_squared"]))
score = (1 - prior["weight"]) * base + prior["weight"] * position
```

7.3 双椭圆空间约束与侧向姿态候选

确定双眼中心 $\mathbf{p}_L, \mathbf{p}_R$ 后，即可脱离容易受头发干扰的肤色轮廓，在以双眼为基准的局部坐标系下直接推算人脸椭圆。定义双眼中点 $\mathbf{m} = (\mathbf{p}_L + \mathbf{p}_R)/2$、眼距 $d_{\text{eye}} = \|\mathbf{p}_R - \mathbf{p}_L\|_2$、眼线单位向量 $\mathbf{u} = (\mathbf{p}_R - \mathbf{p}_L)/d_{\text{eye}}$，以及朝向面部下方的正交法向量 $\mathbf{v} = (-u_y, u_x)^\top$（取 $v_y \geq 0$）。在 97 张有效训练图上，对脸部真值最大连通块拟合椭圆并投影至 $(\mathbf{m}, \mathbf{u}, \mathbf{v}, d_{\text{eye}})$ 坐标系，按分量取中位数得到固定的五参数几何先验：

$$\alpha_{\parallel} = 0.0159, \quad \alpha_{\perp} = 0.3986, \quad \gamma_{\text{major}} = 2.8942, \quad \gamma_{\text{minor}} = 2.1489, \quad \Delta\theta = -0.7843^\circ. \tag{9}$$

由此，任意检测到双眼的图像可生成正中基础椭圆 E_{base}：中心 $\mathbf{c}_0 = \mathbf{m} + d_{\text{eye}}(\alpha_{\parallel}\mathbf{u} + \alpha_{\perp}\mathbf{v})$，长短轴直径 $(2a_0, 2b_0) = d_{\text{eye}}(\gamma_{\text{major}}, \gamma_{\text{minor}})$，主轴倾角 $\theta_0 = \operatorname{atan2}(v_y, v_x) + \Delta\theta$。仅将 E_{base} 直接光栅化为二值掩膜（不结合任何肤色分割），在 29 张严格检出双眼的验证图上即可取得全局 F1 81.88%（图 13），证实了眼睛锚点对人脸尺度和中心定位的稳定性。

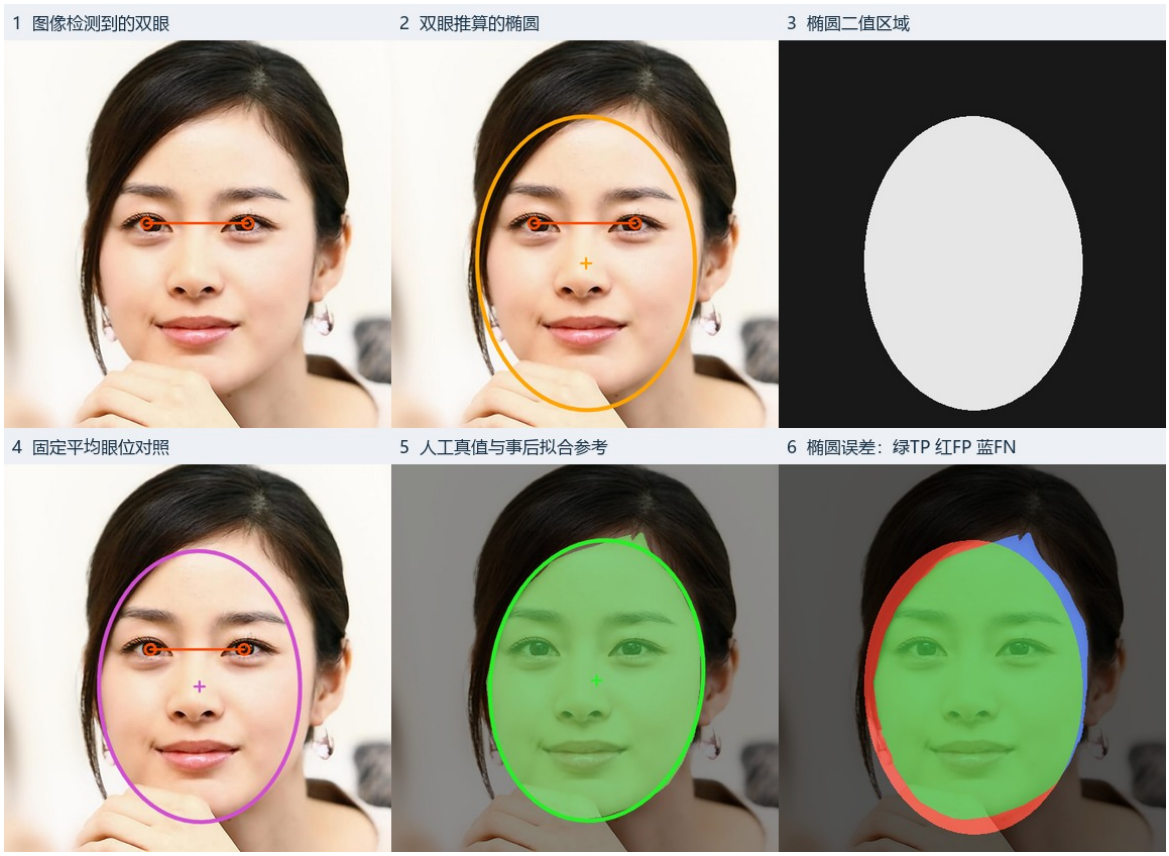


图 13: 验证图 00535 由双眼推算正中脸部椭圆的过程对照。双眼距离与倾角直接决定椭圆中心、长短轴与朝向，无需依赖易受背景污染的肤色外轮廓。

在此基础上，我们进一步引入两项空间结构设计：

1. **针对侧脸与偏转姿态的侧向椭圆候选**：当人脸发生左右偏转（侧脸或四分之三侧面）时，由于透视缩短效应，双眼中点会偏向朝向镜头的一侧，而另一侧脸颊与下颌占画面更宽。为此，沿眼线方向 $\mathbf{u}$ 按眼距比例 $s \in \{0, -0.16, +0.16\}$ 平移椭圆中心，构造正中（`center`）、画面左偏（`image_left`）和画面右偏（`image_right`）三个姿态候选：

$$\mathbf{c}_s = \mathbf{c}_0 + s \cdot d_{\text{eye}}\mathbf{u}, \qquad s \in \{0,\ -0.16,\ +0.16\}. \tag{10}$$

2. **内外嵌套双椭圆分区约束**：椭圆的作用不是直接替代人脸掩膜，而是为形态学处理划定空间边界。对每个姿态候选，保持中心 $\mathbf{c}_s$ 与倾角 θ_0 不变，按比例 $\lambda_{\text{in}} = 0.82$ 与 $\lambda_{\text{out}} = 1.20$ 缩放长短轴，生成**内椭圆** E_{in} 与**外椭圆** E_{out}（满足 $E_{\text{in}} \subset E_{\text{out}}$）：

   - **核心区** E_{in}：代表高置信度面部内部，提取核心种子并允许较强形态学闭运算、填孔及低支持重建；
   - **过渡环带** $E_{\text{out}} \setminus E_{\text{in}}$：包含发际线、脸颊边缘与下颌轮廓，仅允许小尺度弱闭运算修补细缝，优先保留原有颜色边界证据；
   - **外部抑制区** $\overline{E_{\text{out}}}$：直接截断延伸至外椭圆之外的头发、脖颈与背景粘连块，严禁任何形态学扩张越界。

为在不接触真值标签的前提下自动选择姿态候选，我们定义无监督图像支持度评分 S_{cand}：

$$S_{\text{cand}} = 0.55\,\rho_{\text{in}} + 0.20\,\rho_{\text{out}} + 0.20\,r_{\text{ret}} - 0.15\,\rho_{\partial E_{\text{out}}}, \tag{11}$$

其中 $\rho_{\text{in}} = |M_{\text{sel}} \cap E_{\text{in}}|/|E_{\text{in}}|$ 与 $\rho_{\text{out}} = |M_{\text{sel}} \cap E_{\text{out}}|/|E_{\text{out}}|$ 分别为内、外椭圆内的肤色支持率，$r_{\text{ret}} = |M_{\text{sel}}|/|M_{\text{local}}|$ 为外椭圆内保留的核心连通域比例，$\rho_{\partial E_{\text{out}}}$ 为最终掩膜在外椭圆 3×3 腐蚀边界带上的占据率（惩罚紧贴外边界溢出的大块头发或背景误检）。同时，对侧向候选施加优势门槛 $\Delta S_{\text{lat}} = 0.06$（即侧向候选得分必须超过正中候选至少 0.06 才允许偏移），防止近似正脸因局部头发干扰产生无益偏移。

7.4 低支持度放宽肤色阈值重选与分区形态学连接

双椭圆外边界裁剪有效解决了“背景与头发粘连”问题，但对于光照偏暗或严重偏色的样本（如 00548、00562、00660、00733），实验三在 $k = 1.25$ 下的掩膜 M_{Lab3} 落入内椭圆 E_{in} 的像素极少，即便在 E_{in} 内执行常规闭运算也无从连接。

针对这一“内椭圆像素过少”的失效模式，我们设计了**低支持度放宽阈值受限重建机制**：

1. **核心种子提取与低支持判别**：取外椭圆裁剪后的初始掩膜 $M_{\text{local}} = M_{\text{Lab3}} \cap E_{\text{out}}$，仅保留其中与内椭圆 E_{in} 交集不少于 $N_{\text{core}} = 24$ 像素的 8 连通分量，记为 M_{sel}，其内椭圆部分 $S = M_{\text{sel}} \cap E_{\text{in}}$ 作为高可信核心种子。计算内椭圆支持率 $\rho_{\text{in}} = |S|/|E_{\text{in}}|$；当 $\rho_{\text{in}} < \tau_{\text{low}} = 0.18$ 时，判定为低支持度样本。

2. **放宽肤色阈值重选与内椭圆形态学重建**：由第 3 章表 3 可知，当阈值系数从 $k = 1.25$ 放宽至 $k_{\text{rec}} = 2.00$ 时，训练集肤色覆盖率可提升至 91.86%。在全图放宽会引发灾难性背景误检，但在内椭圆 E_{in} 内部放宽则是安全的。因此，仅在低支持样本的 E_{in} 内启用 $k_{\text{rec}} = 2.00$ 的放宽肤色掩膜 M_{relax}，以 27×27 椭圆核执行闭运算连接面部碎片，并严格只保留与高可信种子 S 重叠不少于 24 像素的连通分量，填孔后得到受限重建区域 M_{rec}：

$$\begin{aligned} A &= \left(\text{Close}_{27}(M_{\text{relax}} \cap E_{\text{in}}) \cap E_{\text{in}}\right) \cup S, \\ M_{\text{rec}} &= \text{FillHoles}\left(\bigcup_{C_j \in \mathcal{C}_8(A):\, |C_j \cap S| \geq 24} C_j \right) \cap E_{\text{in}}. \end{aligned} \tag{12}$$

3. **分区形态学连接与种子锚定输出**：内椭圆核心区采用 11×11 强闭运算与填孔（低支持样本并入 M_{rec}），过渡环带 $E_{\text{out}} \setminus E_{\text{in}}$ 采用 5×5 弱闭运算；两者合并为候选掩膜 M_{prop} 后，再次按 8 连通提取与核心种子 S 相交的连通块并做最终填孔：

$$\begin{aligned} M_{\text{prop}} &= \left(\left(\text{FillHoles}(\text{Close}_{11}(M_{\text{sel}})) \cap E_{\text{in}}\right) \cup M_{\text{rec}}\right) \cup \left(\text{Close}_5(M_{\text{sel}}) \cap (E_{\text{out}} \setminus E_{\text{in}})\right), \\ M_{\text{final}} &= \text{FillHoles}\left(\bigcup_{C_j \in \mathcal{C}_8(M_{\text{prop}}):\, C_j \cap S \neq \emptyset} C_j \right) \cap E_{\text{out}}. \end{aligned} \tag{13}$$

代码 **7-2** 给出了低支持重建与分区形态学修整的核心实现。该设计保证了两条硬边界：第一，无论放宽阈值还是闭运算，新增像素绝不越过相应椭圆边界；第二，任何与初始高可信种子 S 不连通的孤立背景或头发块都会在连通域锚定步骤中被清除，从而避免了直接把整个椭圆填满的退化行为。

代码 7-2　低支持放宽阈值重建与双椭圆分区形态学连接（dual_ellipse.py）

```
def reconstruct_low_support(relaxed, seed, inner, kernel_size, minimum_seed_pixels):
    allowed = morphology(relaxed & inner, cv2.MORPH_CLOSE, kernel_size) & inner
    allowed |= seed & inner
    count, labels = cv2.connectedComponents(allowed, connectivity=8)
    retained = [c for c in range(1, count)
                if np.count_nonzero((labels == c) & seed.astype(bool)) >= minimum_seed_pixels]
    return fill_holes(np.isin(labels, retained).astype(np.uint8)) & inner

#                                +
weak = morphology(selected, cv2.MORPH_CLOSE, config["weak_kernel"]) & outer
strong = fill_holes(morphology(selected, cv2.MORPH_CLOSE, config["strong_kernel"])) & inner
if relaxed is not None and inner_support < config["low_support_threshold"]:
    strong |= reconstruct_low_support(relaxed, seed, inner,
                                      config["reconstruction_close_kernel"],
                                      config["minimum_reconstruction_seed_pixels"])
proposal = strong | (weak & (outer & (1 - inner)))
```

```
count, labels = cv2.connectedComponents(proposal, connectivity=8)
anchor_labels = np.unique(labels[seed.astype(bool)])
final = fill_holes(np.isin(labels, anchor_labels[anchor_labels >
    0]).astype(np.uint8)) & outer
```

7.5 验证集消融实验与整体指标提升

我们在 32 张验证图上对侧向椭圆门槛、低支持度放宽阈值系数 k_{rec} 与连接核大小进行了系统消融，完整演进记录见表 20。

表 20: 验证集（32 张）从实验三到实验四各阶段的消融与优化结果，指标单位为百分比

方案与实验阶段	P	R	全局 F1	IoU	均值 F1	升/降/平
原始颜色阈值（$k = 1.25$）	52.43	60.39	56.13	39.01	54.92	–
Lab3 初版（最大连通域 + 填孔）	64.86	82.70	72.70	57.11	70.67	对照基线
Lab3 形态学补全（41 × 41 膨胀填孔腐蚀）	61.77	86.22	71.98	56.22	71.50	19/13/0
Lab4 肤色轮廓椭圆一轮修整（无眼睛定位）	65.66	81.96	72.91	57.37	71.75	–
Lab4 双椭圆基线（$\Delta S_{\text{lat}} = 0.04$，无重建）	79.48	80.06	79.77	66.35	75.69	28/3/1
试验 1：侧向门槛 $\Delta S_{\text{lat}} = 0.06$（无重建）	79.67	80.01	79.84	66.45	75.75	28/3/1
试验 2A：低支持重建（$\rho_{\text{in}} < 0.18, k = 1.55$, 核 15）	–	–	81.24	68.41	–	29/2/1
试验 2B：低支持重建（$\rho_{\text{in}} < 0.18, k = 1.75$, 核 21）	–	–	82.27	69.87	81.22	29/2/1
试验 2C（最终采用）：低支持重建（$k = 2.00$, 核 27）	**79.88**	**86.15**	**82.89**	**70.79**	**82.19**	**29/2/1**
试验 2D（过强，未采用）：低支持重建（$k = 2.25$, 核 33）	–	–	83.50	–	–	趋近填满
事后理想姿态上界（Oracle 选正中/左偏/右偏）	81.18	87.97	84.44	73.07	83.75	诊断上界

消融过程清晰展示了每一步优化的作用与取舍边界：

1. **双椭圆空间约束打破等值线权衡**：引入双眼定位与内外椭圆分区形态学后，即便尚未加入低支持重建（试验 1），验证集 Precision 已从 Lab3 的 64.86% 大幅跃升至 79.67%（+14.81 个百分点），FP 像素从 998,367 锐减至 454,790（减少 54.45%），全局 F1 从 72.70% 提升至 79.84%。

2. **侧向椭圆门槛控制与姿态潜力**：在基线 $\Delta S_{\text{lat}} = 0.04$ 下，有 3 张图像自动选择了侧向椭圆（图像评分优势为 0.043–0.055），但事后核查发现这 3 次偏移均由发丝不对称引起，并未优于正中椭圆。将门槛提高至 $\Delta S_{\text{lat}} = 0.06$ 后，31 张检出双眼的图像全部稳健保留正中椭圆，避免了无益偏移，全局 F1 微升至 79.84%。与此同时，表 20 最后一行显示，若能为每张图准确选取正中/左偏/右偏三者中的最优姿态（Oracle 上界，其中 16 张左偏最优、10 张右偏最优、5 张正中最优），全局 F1 可进一步达 84.44%、IoU 达 73.07%，说明侧向椭圆候选机制本身对偏转人脸确有约 1.55 个百分点的额外空间，当前瓶颈在于仅靠肤色覆盖率还不足以区分“真实侧脸”与“单侧刘海遮挡”。

3. **低支持度放宽阈值重建显著拉升召回率与均值 F1**：在 $\rho_{\text{in}} < 0.18$ 触发条件下（共触发 00548、00562、00660、00733 四张困难样本），随着 $(k_{\text{rec}}, \text{核大小})$ 从 $(1.55, 15)$ 增至 $(2.00, 27)$，验证集 Recall 从无重建时的 80.01% 回升至 86.15%（高于 Lab3 的 82.70%），全局 F1 达到 **82.89%**（比 Lab3 提升 **+10.19 个百分点**），IoU 达到 **70.79%**（比 Lab3 提升 **+13.68 个百分点**），逐图平均 F1 更从 70.67% 提升至 82.19%（+11.52 个百分点）。当继续增大到试验 2D 的 $(2.25, 33)$ 时，虽然验证 F1 升至 83.50%，但 4 张低支持图的重建结果已逼近直接填满整个内椭圆，额头上方黑发误填风险显著上升，违背了“以椭圆约束分割而非替代分割”的原则，故最终定型于试验 2C（$k_{\text{rec}} = 2.00$，连接核 27）。

图 14 将验证集上的五个关键工作点绘制在同一张精确率—召回率平面上。与第 6 章图 10 中 Lab3 形态学补全仅沿 $F1$ 等值线左移截然不同，Lab4 的双椭圆约束先将工作点向右上方大幅推进（大幅削减外部误检），低支持重建再在不损失精确率的前提下将召回率向右推高 6.14 个百分点，实现了精确率与召回率的双重提升。

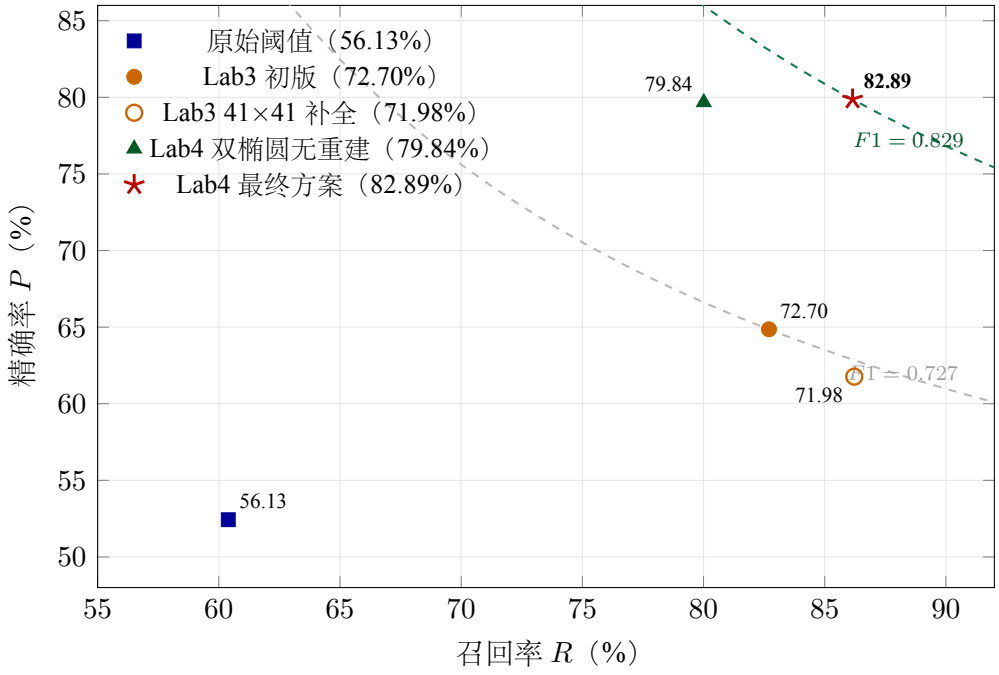


图 14: 验证集（32 张）上实验三与实验四各阶段方案在精确率—召回率平面上的迁移轨迹。实验四通过双椭圆外边界裁剪提升精确率，再通过低支持放宽阈值重建拉升召回率，突破了实验三的 $F1 = 0.727$ 等值线。

7.6 典型案例分析与方法边界

表 21 列出了验证集上触发低支持重建的 4 张困难样本，以及背景粘连裁剪、放宽配对恢复、无双眼回退和轻微退步的代表性样本指标对比。

表 21: 验证集典型样本在 Lab3 与 Lab4 最终方案下的像素变化与指标对照

样本编号	运行机制分支	Lab3 P	Lab4 P	Lab3 R	Lab4 R	Lab3 F1	Lab4 F1	ΔF1
00548	严格配对 + 低支持重建	39.51	57.77	9.01	47.26	14.68	51.99	+37.31
00562	严格配对 + 低支持重建	29.12	77.21	8.33	69.39	12.95	73.09	+60.14
00660	严格配对 + 低支持重建	38.65	73.33	14.08	88.74	20.64	80.31	+59.67
00733	严格配对 + 低支持重建	8.40	53.92	9.01	66.35	8.69	59.49	+50.80
00611	严格配对 + 双椭圆裁剪	32.91	51.11	100.00	100.00	49.52	67.64	+18.12
00632	严格配对 + 双椭圆裁剪	53.96	86.19	97.59	77.38	69.50	81.55	+12.05
00655	放宽眼面积比恢复配对	82.31	95.69	66.86	66.22	73.78	78.27	+4.49
00690	放宽眼面积比恢复配对	61.14	74.85	99.71	80.98	75.80	77.80	+2.00
00592	无双眼配对安全回退	80.96	80.96	93.92	93.92	86.96	86.96	0.00
00712	轻微退步（外椭圆边际）	79.46	79.14	99.88	99.90	88.51	88.32	−0.19
00731	轻微退步（外椭圆边际）	92.35	92.15	99.72	99.73	95.89	95.79	−0.10

结合具体图像可以清楚看到两类核心机制的作用方式：

- **外椭圆抑制大面积背景与头发粘连（方向 B）**：在图 15（样本 00632）中，人物呈微侧脸姿态，棕色长发、脖颈与背景在 $k = 1.25$ 下与脸部连成覆盖大半幅画面的单一连通块，Lab3 精确率仅为 53.96%（F1 为 0.6950）。Lab4 由双眼定出内外椭圆后，外椭圆一次性裁剪掉 74,165 个外部误检像素，使精确率跃升至 86.19%，F1 提高至 0.8155。同时，由于正中椭圆略微切到了画面右侧脸颊边缘（误删 21,134 个 TP 像素），若启用右偏侧向椭圆（`image_right`，Oracle），该图还可进一步减少脸颊裁剪。

- **低支持放宽阈值重建找回碎裂与缺失内脸（方向 A）**：在图 16（样本 00562）与图 17（样本 00660）中，Lab3 因阴影或偏色导致内脸大面积镂空甚至只选中右下颌与脖子（Recall 仅 8.33% 与 14.08%）。由于内椭圆支持率 $\rho_{\text{in}} < 0.18$，算法自动触发 $k_{\text{rec}} = 2.00$ 放宽肤色重选与 27×27 闭运算受限重建：00562 补回 42,481 个真实脸部像素而仅新增 720 个误检像素，F1 从 0.1295 跃升至 0.7309（+0.6014）；00660 补回 38,240 个真实脸部像素，F1 从 0.2064 跃升至 0.8031（+0.5967）。这两例直接修复了第 3 章表 **??** 中列出的验证集最差样本。

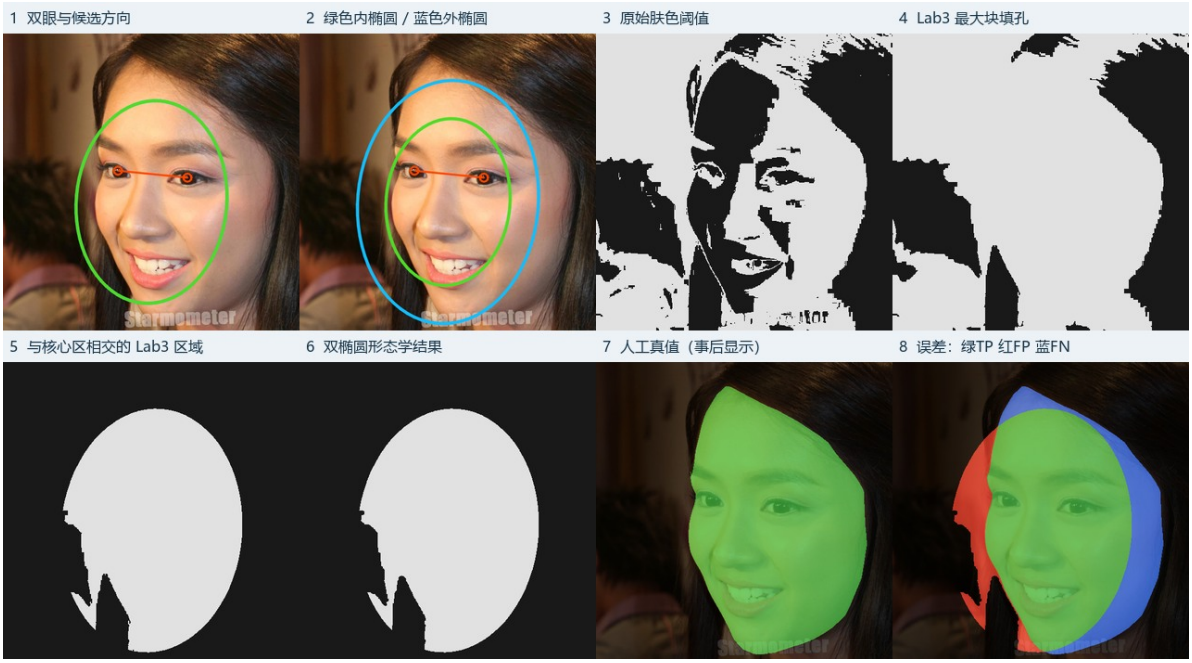


图 15: 验证图 00632 的双椭圆约束形态学全流程对照。外椭圆有效截断了与脸部粘连的大片头发与背景（去除 74,165 个 FP 像素），F1 从 0.6950 提升至 0.8155。

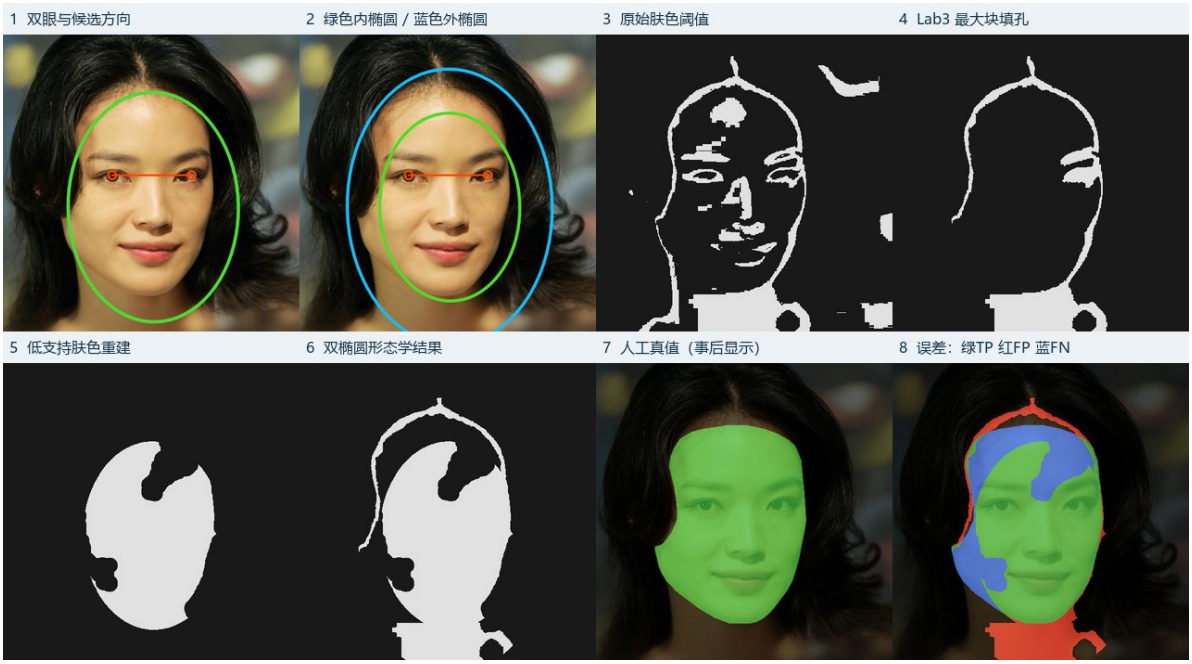


图 16: 验证图 00562 的低支持度放宽阈值重建对照。内椭圆支持率低于 0.18 触发 $k = 2.00$ 放宽肤色重选与 27 像素闭运算连接，在核心区内恢复整张内脸，F1 从 0.1295 提升至 0.7309。

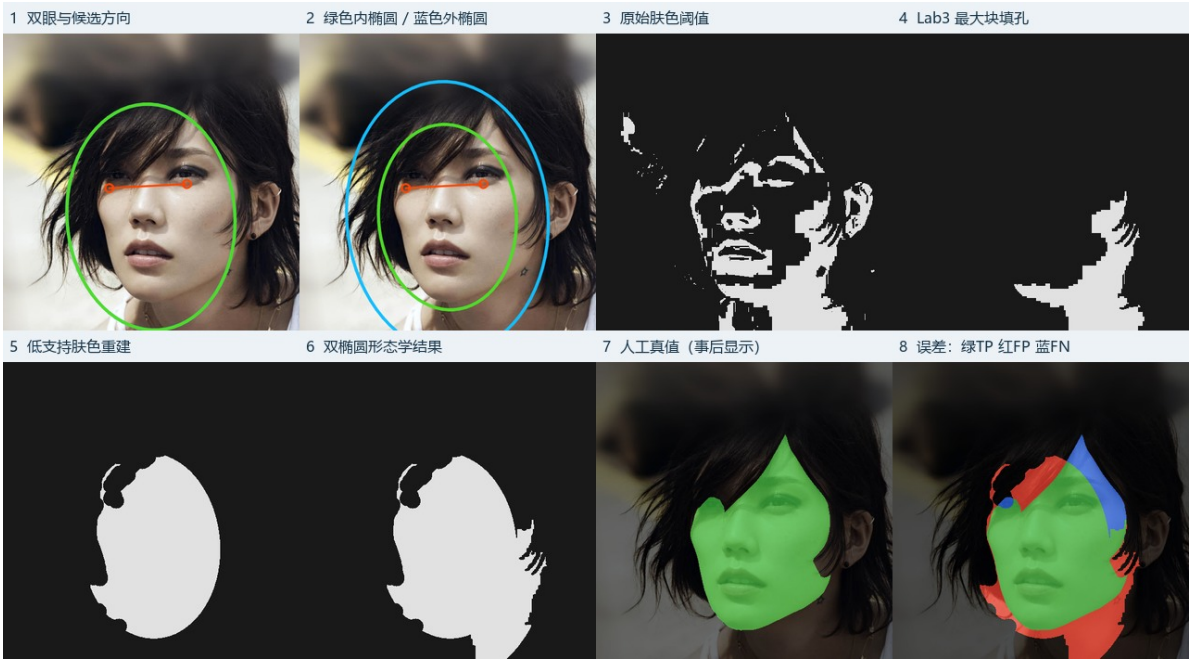


图 17: 验证图 00660 的低支持度放宽阈值重建对照。Lab3 仅检出脖颈与下颌局部（F1 0.2064），双椭圆引导的低支持重建将面部主体完整找回，F1 提升至 0.8031。

最后，必须如实说明实验四方案的四项方法边界与局限：

1. **开发集多轮迭代的证据属性**：实验四的 82.89% 全局 F1 是在 32 张验证图上经过眼睛先验、椭圆缩放与低支持重建参数多轮观察后得到的开发阶段结果，不能直接等同于未见测试集上的无偏泛化性能。

2. **对人像居中构图先验的依赖**：双眼定位在很大程度上依赖训练集统计出的左右眼空间窗口（表 19），若应用于人脸位置偏离中心、尺度变化剧烈或大幅度旋转的非标准人像，固定窗口先验将不再适用。

3. **放宽阈值重建的发际误检代价**：在 00548 与 00733 等暖调头发样本上，$k_{\mathrm{rec}} = 2.00$ 放宽阈值仍会将内椭圆上缘的刘海纳入重建区域（如 00548 新增 18,739 个 FP 像素），说明椭圆内部同样存在色度重叠的头发。

4. **轻微退步样本的边界效应**：验证集中仅有的两张下降样本 00712（$\Delta\mathrm{F1} = -0.0019$）与 00731（$\Delta\mathrm{F1} = -0.0010$）在 Lab3 下已接近完整（Recall 超过 99.7%），分区闭运算在过渡带内微幅连接了少量耳侧或发际边缘像素，导致 F1 出现千分之一量级的波动。

8 结论与反思

本报告从 162 张带像素级标签的图像出发，完整呈现了从实验三（纯颜色阈值与基础连通域后处理）到实验四（双眼引导的双椭圆空间约束与低支持度放宽阈值重建）的递进研究过程。全文的核心问题可以归纳为四个层面的结论。

第一，这批人脸的肤色在 Cr/Cb 色度平面上存在明显聚集，两通道标准差均约为 9.4，相关系数约为 -0.76。但实验三选定的 $k = 1.25$ 矩形阈值仅覆盖训练集肤色的一部分，本质上是一个偏精确率的保守切片，这解释了为何单靠颜色阈值在暗光或偏色图像上容易出现面部碎裂与漏检。

第二，在实验三框架下，颜色阈值配合最大连通域与填孔在 32 张独立测试图上取得全局 F1 70.69%、IoU 54.67%，比纯阈值基线分别提高 8.03 和 9.04 个百分点，主要收益来自排除分离背景误检。阶段分解表明，k 收紧、最大连通域与填孔的像素交换率分别为 1:1.6、1:8.3 和 3.3:1。

第三，纯颜色模型的上限由缺失的几何与语义信息决定，而非由阈值系数或核大小决定。实验三中头发与脖颈占最终误检的 84.0%；无空间约束的 41×41 膨胀—填孔—腐蚀补全虽将测试集召回率提高 4.00 个百分点，但精确率下降 2.80 个百分点，新增像素中仅 35.45% 属于真实脸部，全局 F1（70.70%）几乎不变。这说明无约束形态学只能在精确率—召回率等值线上移动工作点。

第四，实验四证明，通过挖掘灰度图中的五官暗部结构并引入椭圆几何先验，可以在不依赖深度学习检测器的条件下显著突破上述瓶颈。我们首先通过最大连通域分阶段对照与肤色轮廓直接拟合椭圆实验，确认了待修整肤色轮廓本身无法提供可靠椭圆；进而采用灰度黑帽变换结合训练集双窗空间先验定位双眼（验证集 $e \leq 0.25$ 准确率达 28/32，配合两级面积比回退覆盖 31/32 张图，1 张安全回退 Lab3），由眼距与倾角生成正中及左右侧向候选的内外嵌套双椭圆（$\lambda_{\text{in}} = 0.82, \lambda_{\text{out}} = 1.20$，侧向启用门槛 $\Delta S_{\text{lat}} = 0.06$）。在此基础上，外椭圆裁剪截断了大面积粘连的头发与脖颈误检，内椭圆针对支持率 $\rho_{\text{in}} < 0.18$ 的碎裂样本触发 $k_{\text{rec}} = 2.00$ 放宽肤色重选与 27×27 闭运算受限重建，最后经内强外弱的分区闭运算与核心种子连通锚定输出掩膜。在 32 张验证图上，实验四最终方案将 Precision 从 64.86% 提升至 79.88%（+15.02 个百分点），Recall 从 82.70% 提升至 86.15%（+3.45 个百分点），全局 F1 从 72.70% 跃升至 82.89%（+10.19 个百分点），IoU 从 57.11% 提升至 70.79%（+13.68 个百分点），29 张图像改善、仅 2 张出现千分之一量级的轻微回落。

同时，我们也对实验设计的边界保持清醒反思：一是实验三补全方案参考了测试样例反馈，实验四则固定在验证集上进行了多轮消融与选参，报告严格区分了“初版独立测试”“开发后再评价”与“验证集多轮开发结果”三类证据状态；二是当前数据集人像居中对齐度极高，双眼空间先验的显著收益建立在构图一致性之上；三是侧向椭圆在理想姿态选择（Oracle F1 84.44%）下仍有约 1.55 个百分点的提升潜力，未来若结合鼻尖、嘴部或对称梯度等独立姿态线索，有望在不损失正脸稳定性的前提下进一步激活侧脸修正能力。

参考文献

[1] Hsu R L, Abdel-Mottaleb M, Jain A K. Face detection in color images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, 24(5): 696–706.

[2] Vezhnevets V, Sazonov V, Andreeva A. A survey on pixel-based skin color detection tech-

niques[C]. Proceedings of GraphiCon, 2003: 85–92.

[3] Kovac J, Peer P, Solina F. Human skin color clustering for face detection[C]. Proceedings of IEEE EUROCON, 2003, 2: 144–148.

[4] Cheng B, Girshick R, Dollár P, et al. Boundary IoU: Improving object-centric image segmentation evaluation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 15334–15342.

[5] Wang J G, Sung E. Frontal-view face detection and facial feature extraction using color and morphological operations[J]. Pattern Recognition Letters, 1999, 20(10): 1053–1068.

[6] Chai D, Ngan K N. Face segmentation using skin-color map in videophone applications[J]. IEEE Transactions on Circuits and Systems for Video Technology, 1999, 9(4): 551–564.

[7] Garcia C, Tziritas G. Face detection using quantized skin color regions merging and wavelet packet analysis[J]. IEEE Transactions on Multimedia, 1999, 1(3): 264–277.