

数字图像处理实验报告

基于颜色的人脸分割

第三次 Project

课程名称　数字图像处理

小组成员　李维政　24325143

郑立峰　24325341

李睿　24325142

2026 年 11 月 2 日

摘 要

本报告研究颜色空间中的人脸区域分割。实验使用 162 张带像素级标签的图像，按 98/32/32 固定划分；训练集只取皮肤与鼻子像素估计 Cr/Cb 的均值与标准差，验证集比较阈值系数与后处理，测试集只用于固定方案的评价。独立测试中，$k = 1.25$ 的 Cr/Cb 阈值配合最大连通域与填孔取得 F1 70.69%、IoU 54.67%，比纯阈值基线提高 8.03 和 9.04 个百分点，收益主要来自减少误检。

针对独立测试暴露的内部缺口，我们尝试在填孔前加入 41×41 膨胀、填孔后再腐蚀的补全流程。在同一批测试图上，召回提高 4.00 个百分点，精确率下降 2.80 个百分点，F1 基本不变（70.70%）。新增前景中只有 35.45% 属于脸部，误检主要来自头发。这一结果表明，形态学只能移动精确率—召回率工作点，不能改变颜色模型的语义上限：耳朵、脖子与脸部同色，纯颜色判别无法区分；头发与背景的混淆也不能靠补洞解决。

报告据此讨论方法的有效条件、失效层次与适用范围，并把两次实现放在同一张精确率—召回率平面上比较。主要结论是：在受控条件下，颜色模型可以给出可用的粗区域；它的瓶颈不在阈值或核大小，而在颜色本身不包含“这是脸”的语义。

关键词：人脸分割；肤色检测；YCbCr；形态学补全；精确率—召回率

目录

1 问题与路线 **1**
1.1 任务与边界 1
1.2 三个问题 1
1.3 证据状态与章节安排 1

2 数据与评价口径 **2**
2.1 数据来源与筛选 2
2.2 划分与泄漏检查 2
2.3 两套标签：建模用皮肤，评价用整脸 2
2.4 指标：为什么不能只看 Accuracy 3

3 颜色模型与初版方案 **4**
3.1 颜色空间与丢弃 Y 的代价 4
3.2 训练肤色统计 5
3.3 判决规则与验证选参 6
3.4 设计取舍 8

4 初版方案的独立测试 **8**
4.1 测试设置 8
4.2 总体结果 9
4.3 提升来自哪一步 10
4.4 误检从哪里来 10
4.5 逐图稳定性与亮度条件 11
4.6 三类失败 13

5 补全尝试与再次评价 **14**
5.1 从失败分析到可检验的假设 14
5.2 补全流程与核的选择 15
5.3 验证集上的取舍 16
5.4 同一批测试图上的再次评价 16
5.5 收益与代价的图像对照 17
5.6 这次尝试改变了什么，没有改变什么 20

6 颜色模型的能力边界与适用范围 **21**
6.1 方法的实际构成 21
6.2 三个工作点 21

6.3 有效性的来源 22
6.4 失效的来源 23
6.5 适用条件 24
6.6 与其他颜色方法的关系 25
6.7 小结 26

7 结论与反思 **26**

1 问题与路线

1.1 任务与边界

课程要求在一个颜色空间内对亚洲人脸进行分割，并对多幅人脸图像验证。我们把它落实为像素级的人脸区域分割：输入一张 512×512 的彩色图像，输出与原图同尺寸的二值掩膜，1 表示脸部，0 表示其他。评价的正类包括皮肤、鼻子、双眼、双眉、口腔和上下唇；眼镜作为忽略区域，不参加任何混淆计数。

有两个边界需要先说明。第一，肤色掩膜不等于人脸检测，更不等于身份识别。掩膜可能包含脖子、耳朵等皮肤区域，也不保证画面中只有一张脸；本报告不评价识别性能。第二，数据中的“亚洲人脸”来自实验者的外观筛选，没有官方人群属性标签；报告中的结论只对应这批图像及其固定划分，不外推到“所有亚洲人脸”。

1.2 三个问题

全文围绕三个问题展开。第一，这批人脸的肤色在 Cr/Cb 上是否足够集中，均值与标准差能否概括？第二，只靠颜色加两个空间规则，F1 能做到多少，提升来自哪一步？第三，它在什么图像条件下还成立，失败是参数问题还是模型问题？

对应地，我们做了三次判断。第一次是颜色范围：k 取多少。第二次是空间结构：最大连通域与填孔值多少。第三次是补全强度：在填孔前加入膨胀、填孔后再腐蚀，能不能把内部缺口补回来。三次判断各对应一个工作点，后一次都在前一次的结果上提出问题；报告的结构也按这条线展开。

1.3 证据状态与章节安排

初版方案在固定配置后只运行一次测试，得到本报告唯一的独立测试结果。补全尝试的方向来自测试图 00570 的误差，因此它在同一批测试图上的数字只能算开发后的再评价；报告把它单独成章，并在表与图中标注证据状态。两者不合并成一个“最终成绩”。

第 2 章说明数据、标签与评价口径；第 3 章给出颜色模型与初版方案；第 4 章报告独立测试并归纳三类失败；第 5 章接第三类失败，做补全尝试并再次评价；第 6 章把两次结果放在一起，讨论能力边界与适用范围；第 7 章总结。

独立测试的 F1 为 70.69%，补全后为 70.70%，两者几乎相同；差别在召回与精确率的分配。这个数字关系是全文的起点：如果补全不能提高 F1，那么剩下的误差就不在“洞”上。

2 数据与评价口径

2.1 数据来源与筛选

实验使用 Face_segment 数据及其原始多类别像素标签。原始目录并不按人群属性严格划分；我们以外观接近亚洲人脸为目标，从 `test/real_image/2` 中人工筛选，保留对应标签。最初选入 163 对图像与标签；程序核对配对、尺寸与标签取值时发现 00583 与 00584 的图像文件完全相同、标签不同，按人工决定保留 00583、排除 00584，最终得到 162 对。原图均为 512×512 的 RGB 图像，标签为单通道类别图，保留 0–18 共 19 个类别。

数据核查包括原图、彩色标签和半透明叠加图的逐张浏览，没有发现明显的配对或标注问题。这一结论不等于逐像素标注准确性的保证；它只说明数据可以进入后续实验。

2.2 划分与泄漏检查

划分按样本编号排序后用固定种子 42 打乱，得到训练 98、验证 32、测试 32。划分前用 64 位 dHash、汉明距离不超过 8 筛出 35 对相似候选，逐对查看后未发现明显的同照片裁剪或缩放；本次没有核验人物身份，因此这是图像级划分，不声称人物互斥。原数据集目录名 `test` 只是来源信息，本实验在筛选子集内部重新划分。

2.3 两套标签：建模用皮肤，评价用整脸

本实验区分两个区域。肤色建模只用皮肤和鼻子；评价完整脸部时，正类还包括双眼、双眉、口腔和上下唇。眼镜忽略，其余类别为负类。表 1 给出完整映射。

表 1: 原始标签在颜色统计与脸部评价中的用途

用途	标签编号	对应区域
肤色统计	1、2	皮肤、鼻子
脸部评价正类	1、2、4–7、10–12	皮肤、鼻子、双眼、双眉、口腔、上下唇
评价忽略区域	3	眼镜
脸部评价负类	其余类别	背景、双耳、头发、帽子、饰品、脖颈、衣服

这个错位是有意的。眼睛、眉毛和嘴部的颜色不一定接近皮肤；若把它们并入肤色统计，会改变统计对象。但最终目标是完整脸部，所以它们必须计入正类。颜色候选因此天然会在这些位置留下空洞，后面的填孔才有了明确的作用对象。反过来，预测阶段只能使用原图、训练统计和固定配置，不能读取真值或眼镜位置；忽略规则只在评价时生效。实现上只做一次集合判断，见代码 **2-1**。

代码 2-1 脸部真值与有效区域的生成（dataset.py）

```
POSITIVE_IDS = [1, 2, 4, 5, 6, 7, 10, 11, 12]
IGNORE_IDS = [3]

def binary_labels(labels):
    face = np.isin(labels, POSITIVE_IDS).astype(np.uint8)
    valid = np.logical_not(np.isin(labels, IGNORE_IDS)).astype(np.uint8)
    return face, valid
```

这段代码只做两件事：把皮肤、鼻子和五官合并为脸部正类；把眼镜从有效区域中剔除。face 与 valid 分开保存，评价时先按 valid 选像素，再比较 face，所以眼镜像素既不算 TP，也不算 FP。

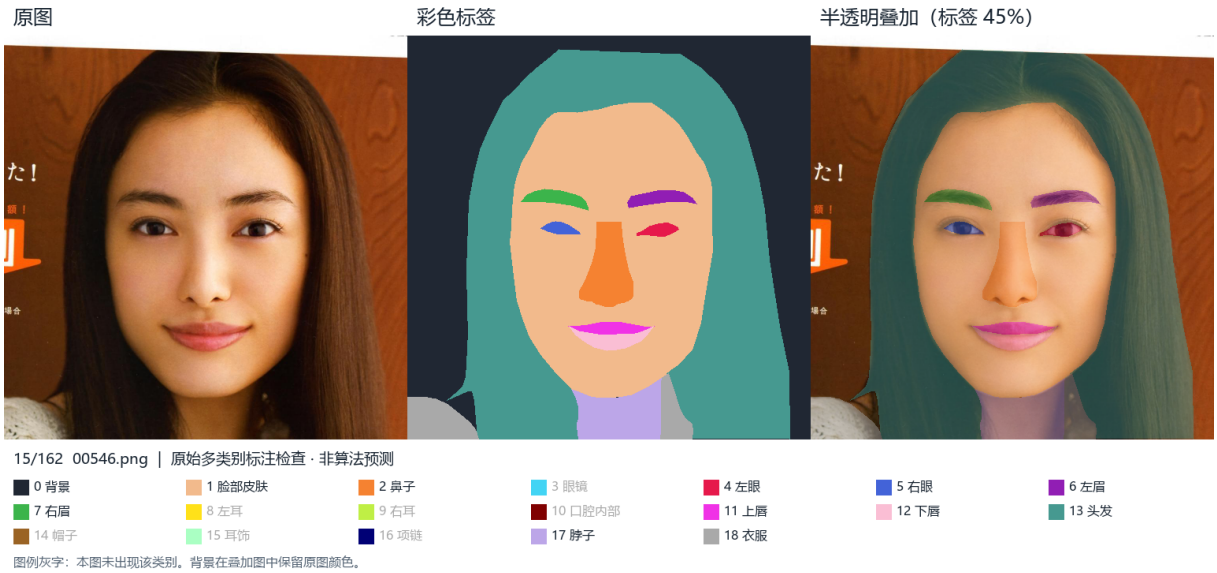


图 1: 样本 00546 的原图、原始多类别标签及叠加核查图。彩色区域来自已有标签，用于检查标注对应关系，并非算法预测。

图 1 展示了原始标签对皮肤、鼻子、眼睛、眉毛和嘴部的区分，也显示头发和脖颈虽与脸部相邻，却属于负类。明确这些边界后，评价才能区分脸部内部缺失与脸部外部误检。

2.4 指标：为什么不能只看 Accuracy

测试集 32 张图共 8,388,608 个有效像素，其中脸部正类 2,150,722 个，占 25.64%。如果把所有像素都判为背景，Accuracy 仍有 74.36%；纯阈值基线的 76.53% 只比这个平凡解高 2.17 个百分点，但它的 F1 是 62.66%。反过来，把所有像素都判为脸部，F1 只有 40.80%。表 2 把这几个参照放在一起。

表 2: 不同预测方式在测试集上的指标对照，单位为百分比

预测方式	Accuracy	Precision	F1
全判为背景	74.36	–	0
全判为脸部	25.64	25.64	40.80
纯阈值基线	76.53	52.91	62.66
初版方案	83.94	66.43	70.69

因此报告以 F1 与 IoU 为主，Precision、Recall 用来解释改善来自哪里，Accuracy 只作补充。多图结果有两种口径：先累加所有图像的 TP/FP/TN/FN 再计算（global），或逐图计算后等权平均（image mean）。前者让脸部面积大的图像占更大权重，后者让每张图权重相同。本报告以 global 为主，逐图平均单独标注，两者不混用。

各指标按式 (1) 计算，所有计数只在有效像素内累加：

$$\begin{aligned} \text{Precision} &= \frac{TP}{TP+FP}, & \text{Recall} &= \frac{TP}{TP+FN}, \\ \text{F1} &= \frac{2TP}{2TP+FP+FN}, & \text{IoU} &= \frac{TP}{TP+FP+FN}. \end{aligned} \tag{1}$$

分母为零时返回空值，而不是 0；全图都被忽略的样本按错误处理，不静默跳过。这样，一张只留下极小块、精确率为 100% 的预测，不会被误当成“完美分割”。

3 颜色模型与初版方案

3.1 颜色空间与丢弃 Y 的代价

YCbCr 把亮度与色度分开。按 ITU-R BT.601，RGB 到 YCbCr 的常用形式为

$$\begin{aligned} Y &= 0.299R + 0.587G + 0.114B, \\ Cr &= 0.713(R-Y) + 128, \\ Cb &= 0.564(B-Y) + 128. \end{aligned} \tag{2}$$

OpenCV 的整数实现与上式略有差异，但通道顺序与含义一致：Y、Cr、Cb，8 位编码 0–255。实现按 BGR 读图，用 `COLOR_BGR2YCrCb` 转换，不做缩放、白平衡或颜色增强。

只用 Cr、Cb 的理由是肤色在色度平面上比在 RGB 中更集中，亮度变化主要落在 Y 上 [1, 2]。代价是丢掉了 Y 中的明暗线索：深色头发和皮肤在色度上可能接近，但在亮度上差别明显。00718 后来正暴露出这一代价；这是当时就知道、但接受了的取舍。

3.2 训练肤色统计

从 98 张训练图取皮肤与鼻子像素，共 $5{,}838{,}561 + 548{,}991 = 6{,}387{,}552$ 个。所有像素等权，不随机抽样，也不先求各图均值再平均；脸部面积大的图像贡献更多像素。对通道 $c \in \{Cr, Cb\}$，均值与总体方差为

$$\mu_c = \frac{1}{N}\sum_{i=1}^{N} c_i, \qquad \sigma_c^2 = \frac{1}{N}\sum_{i=1}^{N}(c_i - \mu_c)^2, \tag{3}$$

其中 $N = 6{,}387{,}552$。计算结果如表 3 上半部分。两通道标准差都约为 9.4，离散尺度接近；这并不表示分类能力相同，因为统计里没有负类。

表 3: 训练肤色统计与阈值覆盖

通道	均值	总体方差	标准差
Cr	151.1495	87.8810	9.3745
Cb	109.1102	89.9380	9.4836

阈值系数 k	1.00	2.00	3.00
范围内训练肤色像素占比	59.17%	91.86%	99.36%

代码 3-1 训练肤色的直方图统计（modeling.py）

```
mask = (labels == 1) | (labels == 2)
ycrcb = cv2.cvtColor(bgr, cv2.COLOR_BGR2YCrCb)
cr = ycrcb[:, :, 1][mask].astype(np.int64)

counts = np.bincount(cr, minlength=256)
n = counts.sum()
values = np.arange(256, dtype=np.float64)
mean = np.dot(values, counts) / n
std = np.sqrt(np.dot((values - mean) ** 2, counts) / n)
```

这段代码先在每张训练图上取皮肤与鼻子像素，累计 256 维直方图，再跨图求和。因为统计对象是直方图而不是逐图像均值，每个像素的权重相同；脸部面积大的图像自然贡献更多像素。方差除以 N 而不是 $N-1$，对应总体方差；σ 由方差开方得到，阈值中使用的是 σ。

联合分布见图 2。高频区域呈倾斜椭圆，按像素频数计算的相关系数约为 -0.7644，协方差为 -67.95：Cr 较大的像素往往对应较小的 Cb。若分别限制两个通道，得到的是轴对齐矩形；它无法贴合倾斜的分布，四角会包含肤色之外的组合，倾斜方向上的肤色又可能被切掉。

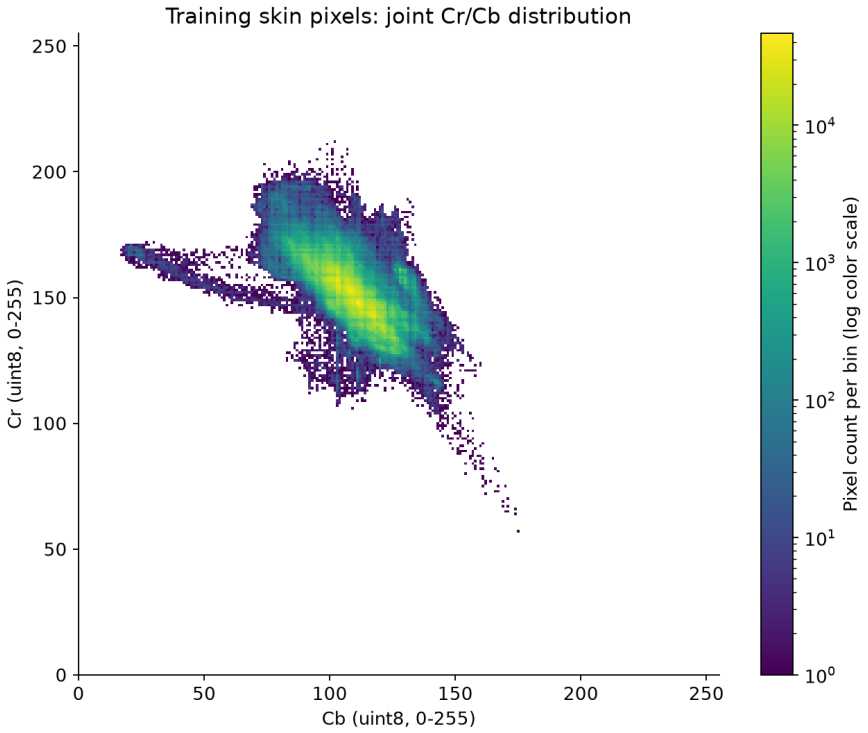


图 2: 训练肤色像素的 Cr/Cb 联合分布。横轴为 Cb，纵轴为 Cr；颜色表示对应整数取值组合的像素数，采用对数刻度。

这个数还有一个用途：估计阈值覆盖了多少训练肤色。表 3 下半部分给出 $k = 1, 2, 3$ 的覆盖比例。$k = 1$ 时矩形只覆盖 59.17%，$k = 2$ 才到 91.86%。也就是说，最终选的 $k = 1.25$ 不是“肤色范围”，而是一个偏精确率的切片：$k = 1$ 时就已经只覆盖 59.17% 的训练肤色，$k = 1.25$ 也远没有覆盖全部。它同时解释了两件事：初版的召回为什么上不去，以及低亮度图像为什么一收紧就掉得厉害。

3.3 判决规则与验证选参

对每个像素，同时满足式 (4) 时记为候选前景：

$$M(x,y) = \begin{cases} 1, & |Cr(x,y) - \mu_{Cr}| \le k\sigma_{Cr} \text{ 且 } |Cb(x,y) - \mu_{Cb}| \le k\sigma_{Cb}, \\ 0, & \text{其他情况.} \end{cases} \tag{4}$$

实现中先转浮点再作差，包含边界；不对每张图像重新估计参数。

颜色候选还需要空间处理。脸部真值包括眼睛、眉毛、口腔与嘴唇，这些位置未必满足肤色范围，容易形成空洞；与脸部分离的类肤色背景则可以通过连通域筛选排除。最终方案先按 8 连通保留面积最大的前景块，再填充不与图像外部背景 4 连通的内部空洞。

代码 3-2 阈值判决与填孔（detection.py）

```
converted = cv2.cvtColor(image_bgr, cv2.COLOR_BGR2YCrCb).astype(np.float64)
cr, cb = converted[:, :, 1], converted[:, :, 2]
mask = ((np.abs(cr - mean_cr) <= k * std_cr) &
        (np.abs(cb - mean_cb) <= k * std_cb)).astype(np.uint8)

def fill_holes(mask):
    padded = np.pad(mask.astype(np.uint8), 1)
    cv2.floodFill(padded, None, (0, 0), 2, flags=4)
    return (padded[1:-1, 1:-1] != 2).astype(np.uint8)
```

这段代码有两个细节。第一，相减前先转成浮点，避免 `uint8` 回绕；比较使用 `<=`，边界像素算作候选。第二，填孔先在外围补一圈零，再从 `(0,0)` 出发按 4 连通把外部背景标成 2；没有被标到的零像素就是被前景围住的洞，最后统一置 1。补零保证即使目标贴着图像边缘，外部种子仍然有效。

验证集 32 张，比较 9 个 k（1 到 3，步长 0.25）与 4 种处理（无、填孔、最大区域加填孔、闭运算后最大区域加填孔），共 36 组。主指标是全局 F1；平局先选更简单的处理，再选较小的 k。计划在运行前写入配置文件。

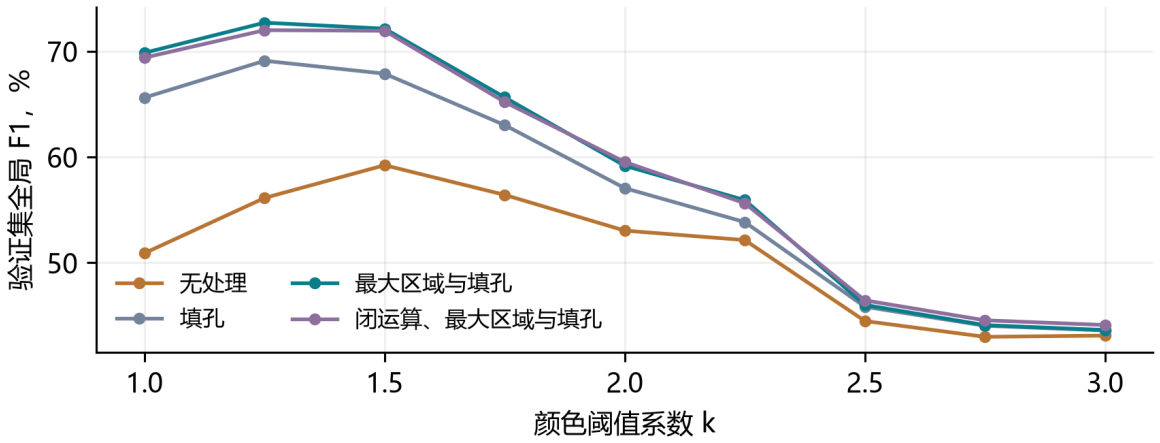


图 3: 四种处理方式在验证集上的参数曲线。横轴为颜色阈值系数 k，纵轴为全局 F1。

图 3 有两个特征。第一，1.25 到 1.5 之间几乎是平台，两者相差不到 0.5 个百分点；最终选 1.25，一部分原因是平局规则，一部分原因是更小的 k 在测试前更保守。第二，k 超过 1.5 后 F1 断崖式下降：颜色范围一放宽，头发和背景就被并进最大连通域，F1 从 72 降到 65、再到 59。失效是结构性的，不是渐进的精度损失。

在相同 $k = 1.25$ 下比较四种后处理，结果如表 4。填孔把 F1 从 56.13 拉到 69.10，是收益最大的一步；最大连通域再加 3.60 个点；闭运算反而低 0.71 个点。我们原本更看好闭运算，觉得它才像“把眉眼补上”，但它在验证集上不如填孔。原因后来在补全实验里才想清楚：闭运算先改变连通性，会把脸和脖子、头发粘在一起，最大区域更容易选错；填孔只填被围住的洞，不动外轮廓。

表 4: 相同颜色阈值下四种后处理的验证结果，单位为百分比

后处理	Precision	Recall	F1	IoU
无处理	52.43	60.39	56.13	39.01
填孔	58.34	84.71	69.10	52.78
最大连通域加填孔	64.86	82.70	72.70	57.11
闭运算后最大区域加填孔	63.39	83.30	71.99	56.24

最终固定 $k = 1.25$、最大连通域加填孔，记为初版方案。它在验证集上的 P/R/F1/IoU 为 64.86/82.70/72.70/57.11。这个配置随后只运行一次测试，结果见第 4 章。

3.4 设计取舍

表 5 列出当时主动放弃的几种做法。它们不是事后补的理由，而是当时的设计边界；第 4 章与第 5 章的失败会逐一回到这些边界上。

表 5: 设计取舍与后来看到的代价

放弃的做法	原因	后来看到的代价
使用 Y 通道	让阈值只管颜色，减少曝光影响	深色头发与皮肤难分（00718）
逐图自适应阈值	保持一个全局模型，避免每图调参	偏色图像无法自救（00609）
椭圆或马氏距离	实现简单、结果可解释	矩形四角包含非肤色；-0.76 的相关性未利用
深度分割模型	课程目标与可解释性	语义鸿沟只能靠后处理绕开
多人处理	数据中没有多人标注	最大连通域只保留一个主体

其中“椭圆或马氏距离”值得多说一句。RGB 规则更简单，但三个通道都混有亮度信息 [3]；椭圆边界不需要更换颜色空间，只需在均值、标准差之外增加一个相关系数，就能利用 -0.76 的联合关系。本实验没有实现它，因此不能给出它可能带来的提升；这里只把它作为由数据直接支持的一个判断记录下来。

4 初版方案的独立测试

4.1 测试设置

测试使用固定划分中的 32 张图，每张 512×512，共 8,388,608 个有效像素。检测只读原图、训练统计和固定配置；评价程序再读取保存的预测，与独立生成的真值对齐。

测试集没有参与选参，也没有在测试后修改配置。当前测试图中没有眼镜像素，忽略逻辑保留但未被触发。

评价只做像素计数，不调用检测函数内部的状态；核心循环见代码 **4-1**。

代码 4-1 有效区域内的混淆计数与指标（evaluation.py）

```
valid = (np.ones(gt.shape, dtype=bool) if valid_mask is None
         else valid_mask.astype(bool))
not_pred, not_gt = np.logical_not(pred), np.logical_not(gt)
tp = np.count_nonzero(pred & gt & valid)
fp = np.count_nonzero(pred & not_gt & valid)
tn = np.count_nonzero(not_pred & not_gt & valid)
fn = np.count_nonzero(not_pred & gt & valid)

precision = tp / (tp + fp) if tp + fp else None
recall    = tp / (tp + fn) if tp + fn else None
f1        = 2 * tp / (2 * tp + fp + fn) if (2 * tp + fp + fn) else None
iou       = tp / (tp + fp + fn) if (tp + fp + fn) else None
```

这段代码用逻辑与同时完成“预测为正”和“真值为正”的筛选：`pred` 是预测掩膜，`gt` 是脸部真值，二者都是 0/1 数组；`valid` 把眼镜像素排除在四个计数之外。分母为零时返回 `None`，不做静默填零。汇总时先把所有图像的 TP/FP/TN/FN 相加再计算 global，逐图平均则单独对每张图的指标做等权平均；两种口径在报告中始终分开标注。

4.2 总体结果

总体指标与混淆计数分别见表 6 和表 7。

表 6: 测试集总体指标，单位为百分比

方案	Precision	Recall	F1	IoU
纯阈值基线	52.91	76.82	62.66	45.63
初版方案	66.43	75.55	70.69	54.67
变化，百分点	+13.52	−1.27	+8.03	+9.04

表 7: 测试集混淆计数

方案	TP	FP	TN	FN
纯阈值基线	1,652,227	1,470,496	4,767,390	498,495
初版方案	1,624,818	821,271	5,416,615	525,904

初版相对基线：F1 提高 8.03 个百分点，IoU 提高 9.04 个百分点；Precision 提高 13.52，Recall 下降 1.27。计数上，FP 减少 649,225，FN 增加 27,409。收益主要来自减少误检，而不是找回漏检。

初版相对基线的变化主要是“删掉不该选的”，而不是“把漏掉的找回来”。召回基本不动，精确率大幅上升；这也解释了为什么初版的 F1 停在 70% 附近——它把颜色候选修剪得更干净，但没有增加新的判别信息。

4.3 提升来自哪一步

把流程拆成四个阶段，可以看到每一步拿什么换什么，结果如表 8。

表 8: 固定流程各阶段的测试结果，指标单位为百分比

阶段	Precision	Recall	F1	FP	FN
基线阈值，$k = 1.50$	52.91	76.82	62.66	1,470,496	498,495
颜色阈值，$k = 1.25$	56.59	65.24	60.61	1,076,315	747,523
保留最大连通域	64.73	63.36	64.04	742,515	787,938
填孔后的结果	66.43	75.55	70.69	821,271	525,904

三步的交换率不同。k 从 1.50 收到 1.25，去掉 394,181 个误检像素，也丢掉 249,028 个正确像素，约合 1 个 TP 换 1.6 个 FP；最大连通域去掉 333,800 个误检，只损失 40,415 个正确像素，约合 1 个 TP 换 8.3 个 FP；填孔补回 262,034 个正确像素，同时增加 78,756 个误检，约合 1 个 FP 换 3.3 个 TP。

单看 k 收紧这一步，F1 从 62.66 降到 60.61，是亏的；它是在给后面的最大连通域让路。最大连通域是最划算的一步；填孔再把内部补回来。三步不能分开评价：阈值、区域和填孔之间存在配合关系，单独调其中一步会得到不同的“最优”。

4.4 误检从哪里来

表 9 把最终误检按原始类别归类，并给出填孔前后两组正类的组内召回。

表 9: 最终误检的语义来源与五官召回

负类	基线 FP	最终 FP	占最终 FP
头发	772,905	497,516	60.58%
脖颈	248,769	192,139	23.40%
背景	369,581	93,639	11.40%
衣服	58,056	20,420	2.49%
双耳	17,665	14,184	1.73%
其他	3,520	3,373	0.41%

正类分组	最大区域后	填孔后
皮肤与鼻子	66.43	76.27
眼、眉、口腔与嘴唇	32.61	68.32

头发和脖颈合计占最终误检的 83.98%。头发容易形成类肤色候选；脖颈则与脸部颜色相近，又常常连在同一前景块上，最大连通域无法把它切开。所以剩余问题不只来自分离的背景，也来自与脸部同色或相连的区域。

其中脖子和耳朵本身是皮肤，这是方法的语义上限。测试集中脖子与双耳合计约 37.4 万像素，而脸部正类约 215 万像素。即使颜色判决完全正确、不再产生任何头发或背景误检，只要结构仍是“最大连通域加填孔”，这部分像素仍会被计入前景，精确率的上限约为 85%。当前精确率 66.43%，离上限还有约 19 个百分点；即使把头发和背景误检全部消除，纯颜色模型也无法达到更高的精确率。这个计算假设所有肤色像素都被判为正类，实际方法可能因连通性排除部分耳朵，因此 85% 是量级上的上限，不是严格界。

填孔确实恢复了五官：眼、眉、口腔与嘴唇的组内召回从 32.61% 提高到 68.32%，补回 69,662 个正确像素；皮肤与鼻子组从 66.43% 提高到 76.27%。方法并不知道那些像素是眼睛或嘴，它只是利用了它们被脸部轮廓包围这一拓扑事实。

4.5 逐图稳定性与亮度条件

逐图指标与亮度分组见表 10。

表 10: 逐图指标、边界质量与亮度分组

统计项目	基线	初版
逐图 F1 平均	0.628	0.681
逐图 F1 中位数	0.664	0.778
逐图 F1 最小值	0.273	0.031
逐图 F1 最大值	0.907	0.930
Boundary IoU 平均	0.153	0.233

亮度分组	图像数	基线 F1	初版 F1
较低	11	56.56	52.82
中间	11	61.90	74.88
较高	10	69.43	83.00

32 张图中有 27 张 F1 提高、5 张下降。中位数从 0.664 升到 0.778，但最小值从 0.273 降到 0.031：多数图像受益，少数图像变差，而且变差得更厉害。逐图 F1 几乎呈两段分布：11 张不低于 0.85，5 张低于 0.2，0.2 到 0.5 之间没有样本。这个形态与“方法依赖一个占主导的肤色连通区域”的解释一致；样本只有 32 张，形态也可能带有偶然性。

按图像配对重采样 10,000 次，总体 F1 差值的 95% 区间为 $+3.57$ 至 $+12.00$ 个百分点；逐图平均 F1 差值的区间为 -0.68 至 $+10.60$ 个百分点。后者跨过 0，说明改善集中在部分图像上；只报一个总体 F1 会掩盖这一点。

按真值脸部平均 Y 排序，把测试图分成 11、11、10 张的较低、中间、较高亮度三组。较低亮度组的 F1 反而从 56.56 降到 52.82，正确像素减少约 9.6 万、漏检增加约 9.6 万；中、高亮度组则分别提高 13 和 13.6 个百分点。低亮度下肤色色度偏离训练分布，$k = 1.25$ 把真肤色也切掉了，减少的误检不足以补偿。需要说明，亮度分组是事后按真值区域平均 Y 划分的，只有 11 张图，且亮度与场景、肤色、妆容混杂；这里只能说明低亮度条件下风险更高，不能把下降单独归因于亮度。

另外采用 Boundary IoU 观察轮廓贴合程度 [4]：使用预测和真值各自的内侧边界带，带宽取图像对角线的 2%（当前为 14 像素），逐图平均后从 0.153 升到 0.233。区域重合改善的同时，边界也有所改善，但 0.233 仍然不高；掩膜看起来完整，边缘并不可信。

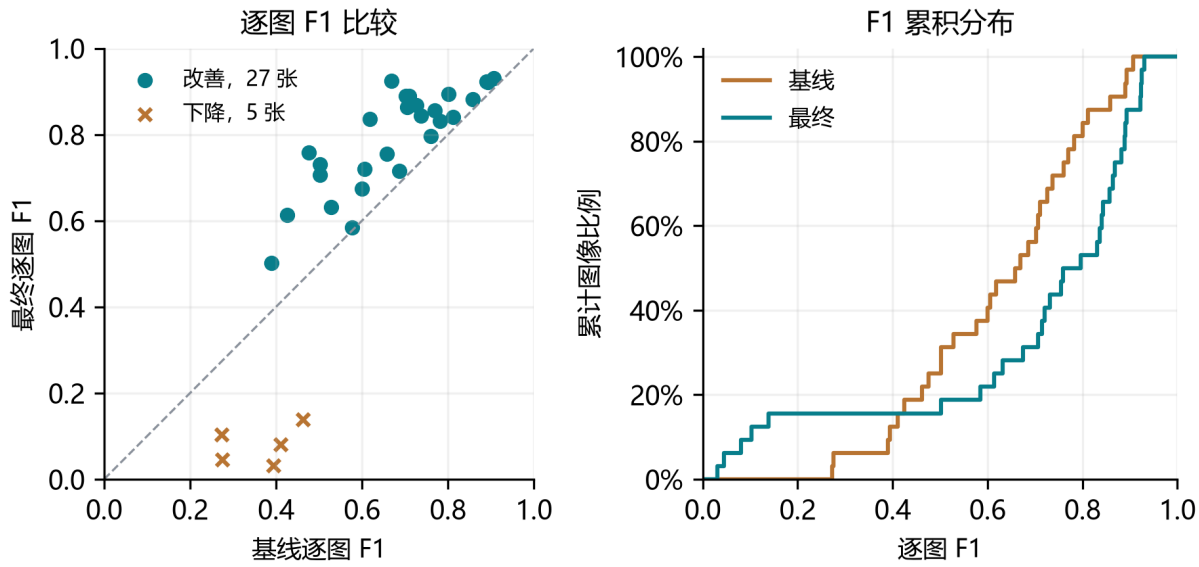


图 4: 逐图 F1 比较与累积分布。左图每个点对应一张测试图，虚线上方表示初版更高；右图为 F1 累积分布。

图 4 同时给出逐图变化和低分尾部。5 张退步图中，有 3 张的 Precision 是 100%——00609、00583、00735 的召回分别只有 1.6%、4.2%、7.4%。掩膜里留下的像素确实都在脸上，但整张脸几乎没被找到。只看“干不干净”，它们接近满分；按 F1 算，它们和全黑没有本质区别。

4.6 三类失败

把 32 张误差图逐张看过去，失败可以归成三类。

第一类是颜色候选不足。00609 在 $k = 1.25$ 下只剩 5,685 个候选像素，分成 56 个连通块，最大块 1,063 像素；最终召回 1.6%，F1 0.031。图像整体偏冷，肤色被推到训练范围之外；错误在颜色阶段就发生了，后面的区域选择和填孔只是没能救回来。

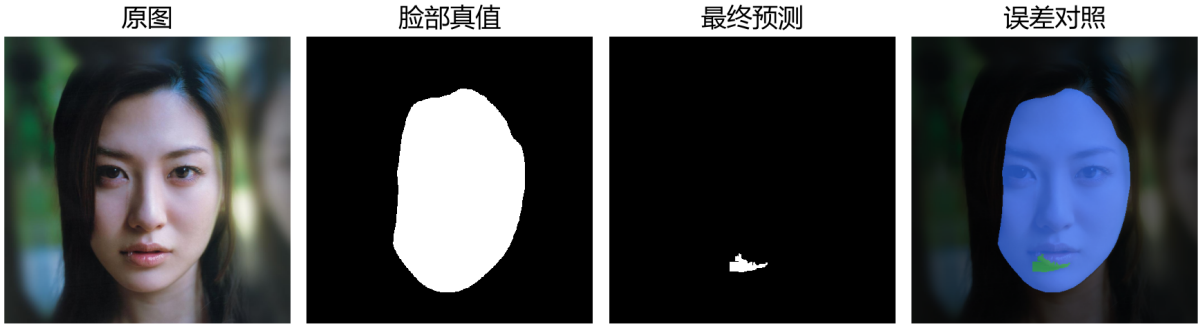


图 5: 00609 的原图、真值、初版预测与误差对照。颜色候选不足导致大面积漏检。

第二类是区域选择错误。00718 中，棕色头发形成 58,716 像素的最大连通块，其中正确像素只有 2,705 个；填孔又增加 110 个正确像素和 10,871 个误检像素，最终 F1 0.045。面积只能表示区域大小，不能表示区域属于什么。

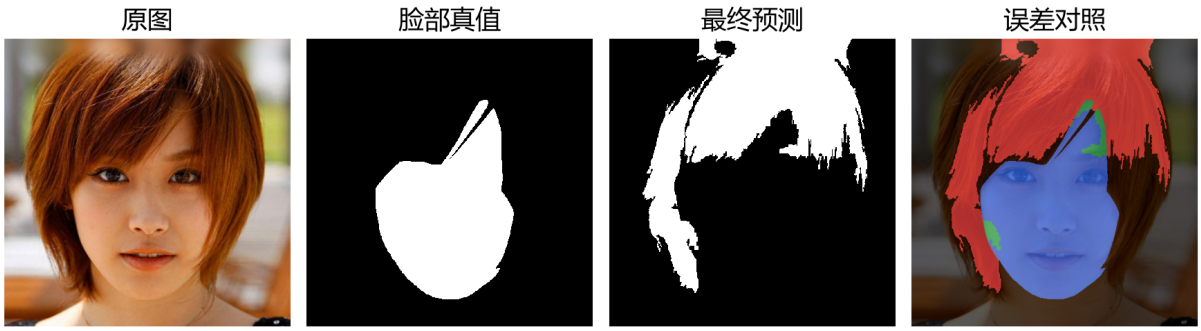


图 6: 00718 的原图、真值、初版预测与误差对照。头发被选为主要候选，填孔扩大了误检。

第三类不同：主体大致正确，但眼睛、嘴部与外部背景连通，填孔补不回来。00570 是一个清楚的例子，嘴部有一条横向缺口；它的 F1 是 0.759，召回 0.631，主要缺失不是“选错”，而是“补不上”。前两类属于颜色与区域的边界，在现有框架内没有便宜的修法；第三类只涉及“如何把开口封住”，可以单独做一次实验。下一章从这里开始。

5 补全尝试与再次评价

第 4 章的失败可以归成三类：颜色候选不足、区域选择错误、主体正确但内部缺口与外部连通。前两类在现有框架内没有便宜的修法——放宽 k 会把头发和背景一起放进来，换区域评分则要引入新的形状假设。第三类不同，它只涉及“如何把开口封住”，可以在不改颜色规则的前提下单独做一次实验。

00570 是一个清楚的例子。初版在 $k = 1.25$ 下得到 68,205 个候选像素，最大连通域保留 27,687 个，填孔后为 37,867 个；F1 为 0.759，召回率为 0.631。误差图上最显眼的是嘴部的一条横向缺口：它与外部背景连通，按填孔的定义不属于“内部空洞”，所以一直留在掩膜里。额头上方也有较大的缺失，但那一块与外部连通得更宽，不是这次能处理的。

5.1 从失败分析到可检验的假设

如果缺口是窄的，先膨胀可以把开口封住；封住之后，填孔就能把内部区域当成封闭空洞补上；最后腐蚀收回外缘。由此可以预期：召回上升，精确率下降，F1 可能基本不变。这个预期在实验前就可以写下来，后面的结果正好可以用来检验它。

补全的作用范围由最大连通域限制，因此它和“放宽 k”不同：后者会在全图扩大颜色候选，头发和背景会一起进来；前者只在已选中的主体周围封口，针对的是“主体大致正确、只是缺口”的情形。这也是我们选择形态学而不是继续调阈值的原因。

最终采用的顺序是：最大 8 连通域 $\rightarrow$ 41×41 椭圆核膨胀 $\rightarrow$ 填孔 $\rightarrow$ 同核腐蚀。膨胀和腐蚀各执行一次；处理前在图像外围补零，全部步骤结束后再裁回原尺寸，避免有限边界让腐蚀多削掉贴边目标。核的直径按原图像素计，当前数据为 512×512；换分辨率需要重选，不能直接照搬。

闭运算也能封口，但它在填孔之前就把外缘收了回去；如果窄开口在腐蚀后重新打开，填孔仍会把它当作外部背景。把填孔放在膨胀与腐蚀之间，填孔面对的是仍然封闭的轮廓，内部区域才能被补上；最后的腐蚀只收回外缘，不撤销已经填入的内部像素。这是我们在实现前的判断，验证集上的结果与它一致：最终选中的正是这个顺序。

代码 5-1 补全流程的核心步骤（detection.py）

```
count, labels, stats, _ = cv2.connectedComponentsWithStats(mask,
    connectivity=8)
if count > 1:
    component = 1 + int(np.argmax(stats[1:, cv2.CC_STAT_AREA]))
    mask = (labels == component).astype(np.uint8)

element = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (kernel, kernel))
pad = kernel
padded = np.pad(mask, pad)
padded = cv2.dilate(padded, element, iterations=1, borderValue=0)
padded = fill_holes(padded)
padded = cv2.erode(padded, element, iterations=1, borderValue=0)
return padded[pad:-pad, pad:-pad].astype(np.uint8)
```

这段代码的顺序与设计一致：先选最大连通域，再膨胀，避免被丢弃的小块在膨胀时重新接回主体；随后填孔，此时开口已经被封住；最后用同核腐蚀收回外缘。处理前按核大小补零，所有步骤结束后才裁回原尺寸，这样贴边目标不会因为数组边界被额外削掉。41×41 是当前 512×512 数据上的选择，换分辨率需要重选。

这样得到第二版代码和结果。需要先说明这次尝试的性质：它的方向来自 00570 的测试误差图。测试分数没有参与选核，但测试样例参与了问题定义；因此第二版在同一批测试图上的数字只能算开发后的再评价，不再独立。第 4 章的 70.69% 仍是本报告唯一的独立测试结果；本章的 70.70% 用来回答“补全改变了什么”，不用来回答“方法有多好”。

5.2 补全流程与核的选择

核大小来自验证集上的 15 组候选：纯阈值、初版、旧 5×5 闭运算参考，以及两种补全顺序各自的 $5, 9, 15, 21, 31, 41$ 六种核。第一轮按全局 F1 比较，初版仍是 72.70%，其余候选中没有一组超过它。这个结果本身是有信息的：如果目标只是最高 F1，补全没有存在的理由。

我们随后把目标改成“在 F1 损失不超过 1 个百分点的前提下最大化召回”，因为这次改进的目标就是减少缺口，而不是提高 F1。改动写在第二次运行之前，计划文件也记录了这次尝试参考过 00570；但它发生在看到第一轮结果之后。严格说，验证集被用了两次。这不会让结果失效，但会放大验证集的乐观偏差；我们在报告里保留这个过程，而不是只写最后选中的配置。

新规则下，41×41 被选中。它同时是核网格的上界；在新候选中，核越大召回越高，规则自然会选到最大。41×41 的验证 F1 为 71.98%，比初版低 0.72 个百分点——这个

差距是规则允许的，也是我们主动接受的。换句话说，第二版的分数结构在选核之前就定了：它注定用约 0.7 个点的 F1 换约 3.5 个点的召回。

41 像素约等于图像宽度的 8%。这已经不是一个去噪级别的操作，而是一次大幅度的区域扩张；后面的误检增长，很大程度上来自这个尺度。

5.3 验证集上的取舍

结果如表 11。

表 11: 补全前后的验证结果，单位为百分比

方案	Precision	Recall	F1	IoU
初版	64.86	82.70	72.70	57.11
补全后	61.77	86.22	71.98	56.22
变化，百分点	−3.09	+3.52	−0.72	−0.89

验证集上，补全减少 78,523 个漏检像素（−20.37%），增加 190,636 个误检像素；召回提高 3.52 个百分点，精确率下降 3.09 个百分点。这个交换在方向上符合预期，在幅度上则提醒我们：补全不是没有代价的。它把判决边界向外推，边界内的像素不会自动变成脸。

F1 只下降 0.72 个百分点，而精确率下降了 3.09 个百分点。原因在分母：精确率的分母是预测前景，召回的分母是真实前景；这次新增的误检像素多于恢复的正确像素，所以精确率的下降比召回的上升更显眼。这个关系在测试集上还会出现。

5.4 同一批测试图上的再次评价

结果如表 12。

表 12: 补全前后的测试结果，单位为百分比

方案	Precision	Recall	F1	IoU
初版	66.43	75.55	70.69	54.67
补全后	63.63	79.55	70.70	54.68
变化，百分点	−2.80	+4.00	+0.01	+0.01

测试集上的方向与验证集一致，幅度更大：召回 +4.00，精确率 −2.80，F1 只差 0.01 个百分点。TP 从 1,624,818 增加到 1,710,868（+86,050），FN 从 525,904 降到 439,854（$-86,050$），FP 从 821,271 增加到 977,980（+156,709）。TP 与 FN 正好互补，说明补全没有删掉任何原有前景像素——两版掩膜的差异只有新增，没有删除。

新增的 242,759 个前景像素中，86,050 个是脸（35.45%），156,709 个不是（64.55%）。表 13 给出新增像素的语义来源。

表 13: 新增前景像素的来源

真实区域	新增正确像素	新增误检像素
皮肤与鼻子	68,758	0
眼、眉、口腔与嘴唇	17,292	0
头发	0	116,896
背景	0	20,534
脖颈	0	13,043
其他负类	0	6,236
合计	86,050	156,709

新增误检中头发占 74.59%；新增正确像素中，五官组 17,292 个，使眼、眉、口腔与嘴唇的召回率从 68.32% 提高到 79.11%。

这组数字解释了为什么 F1 不动：补全确实把五官补回来了一些，但每补回 1 个正确像素，就同时带进约 1.8 个错误像素。新增区域的正确率只有 35.45%，接近“把边界向外推一圈”所对应的比例。

逐图看，19 张 F1 提高，13 张下降；逐图平均 F1 从 0.681 升到 0.690，但配对重采样的 95% 区间为 -0.45 至 $+2.66$ 个百分点，跨过 0。总体 F1 差值的区间为 -1.27 至 $+1.66$ 个百分点，同样跨过 0。也就是说，这次改动在总体指标上无法与“没有变化”区分。边界 IoU 的逐图均值从 0.233 降到 0.227，说明区域更连续，轮廓反而更不贴合。

如果只以 F1 为准，这次尝试没有带来提升；如果以召回为准，它达到了目的；如果以边界为准，它是退步的。三个判断都成立，取决于把什么当成目标。

5.5 收益与代价的图像对照

00570 的嘴部横向缺口减少，新增 4,367 个正确像素和 1,247 个误检像素，F1 从 0.759 提高到 0.803，召回率从 0.631 提高到 0.707（图 7）。额头和眼周仍有较大缺失：41×41 的核能封住嘴部这种窄开口，封不住额头那种宽缺口。



图 7: 00570 的初版与补全后预测对照。嘴部缺口减少，额头与眼周仍有漏检。

00537 的补全收益最明显（图 8）。召回率从 52.98% 提高到 99.89%，F1 从 0.584 提高到 0.803，新增 25,174 个正确像素和 11,119 个误检像素。掩膜把脸侧头发和肩部一起包了进来，精确率只有 67.06%。这张图说明补全的收益可以很大，但收益的形式是“把主体轮廓向外扩”，不是“把脸部边界找得更准”。



图 8: 00537 找回最多的脸部像素，同时扩大了脸侧误检。

00578 则是另一种情形（图 9）。初版的最大连通域已经落在头发上；补全沿着这块头发继续扩张，新增 22,692 个误检像素，只恢复 1,505 个正确像素，F1 从 0.103 变为 0.105，召回率从 12.57% 升到 14.36%。掩膜看起来更连续，覆盖的仍然是头发，脸还是漏的。

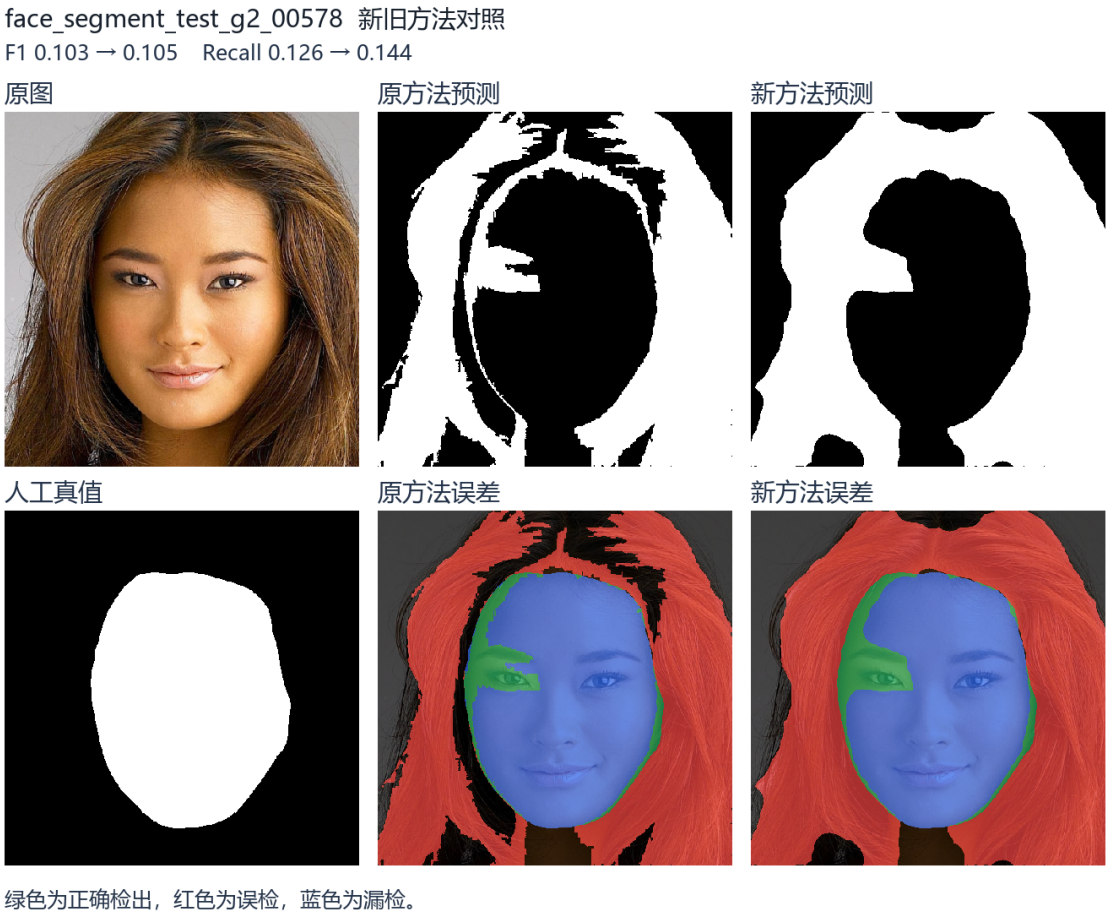


图 9: 00578 中头发误检扩大，脸部主体仍然缺失。

00647 更直接：初版召回已达 99.58%，补全只多恢复 117 个正确像素，却增加 19,907 个误检像素，F1 从 0.720 降到 0.662。对已经接近完整的主体，继续扩张只有代价。

颜色或区域失败的图则几乎没有改善：00609 的召回率从 1.59% 到 1.78%，00718 从 5.12% 到 9.78%。补全只能在候选大致正确时起作用。

5.6 这次尝试改变了什么，没有改变什么

把两次结果放在一起，可以得到一个比 F1 更清楚的判断：补全改变的是覆盖范围，不是判别能力。它把判决边界向外推，被包进来的像素中只有 35% 是脸；它让五官召回提高，也让头发误检增加；它让区域更连续，也让边界 IoU 下降。用一句话说，它把工作点从“偏精确率”移到了“偏召回”，但没有把整条曲线往上抬。

这也解释了为什么 F1 几乎不动：初版和补全后落在同一条 F1 等值线附近（70.69% 与 70.70%），差别只在 P/R 的分配。形态学更像一个工作点参数，而不是一个新的判别模型。

这次尝试仍然是有价值的。它把第 4 章三类失败中的第三类单独拿出来，验证了“缺口可以由拓扑修补部分恢复”这一假设；它也给出了修补的边界：主体大致正确时有效，主体选错时放大错误，颜色候选不足时几乎无效。后两类不是核大小能解决的，它们属于颜色与区域的语义错配。

如果还要往前走，最值得先动的不是核大小，而是让颜色判决知道“这块区域是不是脸”。核大小已经是网格上界，继续加大是否还有收益，本实验没有回答；但 00609 和 00718 的召回只有 1.8% 和 9.8%，说明对这两类失败，核不是主要矛盾。这个问题留到下一章。

最后回到证据边界。如前述，补全后的测试数字是开发后的再评价，不再独立；第 4 章的 70.69% 仍是唯一的独立结果。这个区分不影响本章的机制结论，但影响我们能把 70.70% 写到什么程度。

6 颜色模型的能力边界与适用范围

前五章分别处理了数据、统计、判决、独立测试与补全尝试。本章不引入新的实验，而是回到已经固定的结果，回答一个更基本的问题：这套以 Cr/Cb 阈值为核心的方法，究竟在什么意义上有效，又在什么意义上失效。本章用到的两项统计——F1 分布与精确率上限——均由已保存的逐图像计数和原始类别计数直接算出，没有重新预测，也没有调整参数；它们属于对固定结果的事后解释，不构成新一轮独立测试。

6.1 方法的实际构成

把最终流程拆开，只包含三个判断。第一，像素的 Cr、Cb 是否同时落在以训练均值为中心、以 k 倍标准差为半宽的矩形内；第二，画面中面积最大的 8 连通前景块是否就是脸部；第三，不与图像边界连通的前景空洞是否属于脸部。三者分别对应颜色先验、单主体先验和闭合轮廓先验。补全只是把闭合先验做得更强，没有增加新的判别信息。

这三个先验都不涉及“脸长什么样”。方法没有使用形状、纹理、边缘或五官位置，并在颜色转换后主动丢弃了 Y 通道。因此，我们更愿意把它描述为“肤色检测加两个空间约束”，而不是“人脸分割”。后文对优劣的判断都建立在这一认识上：误差主要不来自阈值是否精细，而来自三个先验在具体图像上是否成立。

这种简化并非疏忽。丢弃 Y 是为了让判决只依赖色度，减少曝光变化的影响；采用最大连通域，是为了在不引入人脸检测器的前提下排除零散干扰；填孔则是为了在不使用五官标签的前提下恢复眼睛、眉毛和嘴部。三项选择都以“不引入额外模型”为代价，换取实现的简单与结果的可解释。这些代价在第 4 章与第 5 章的失败样例中均有体现。

6.2 三个工作点

表 14 把三次判断的结果放在一起。纯阈值是颜色单独作用时的位置；初版加入区域与填孔；补全再加膨胀与腐蚀。

表 14: 三种方案在测试集上的位置与证据状态

方案	Precision	Recall	F1	IoU	证据状态
纯阈值	52.91	76.82	62.66	45.63	独立测试
初版	66.43	75.55	70.69	54.67	独立测试
补全后	63.63	79.55	70.70	54.68	开发后对比

初版把精确率从 52.91 拉到 66.43，召回几乎不动；补全把召回推到 79.55，精确率退回 63.63。初版与补全后落在同一条 F1 等值线附近；基线不在同一条线上，F1 低约 8 个百分点。图 10 把这层关系画了出来。

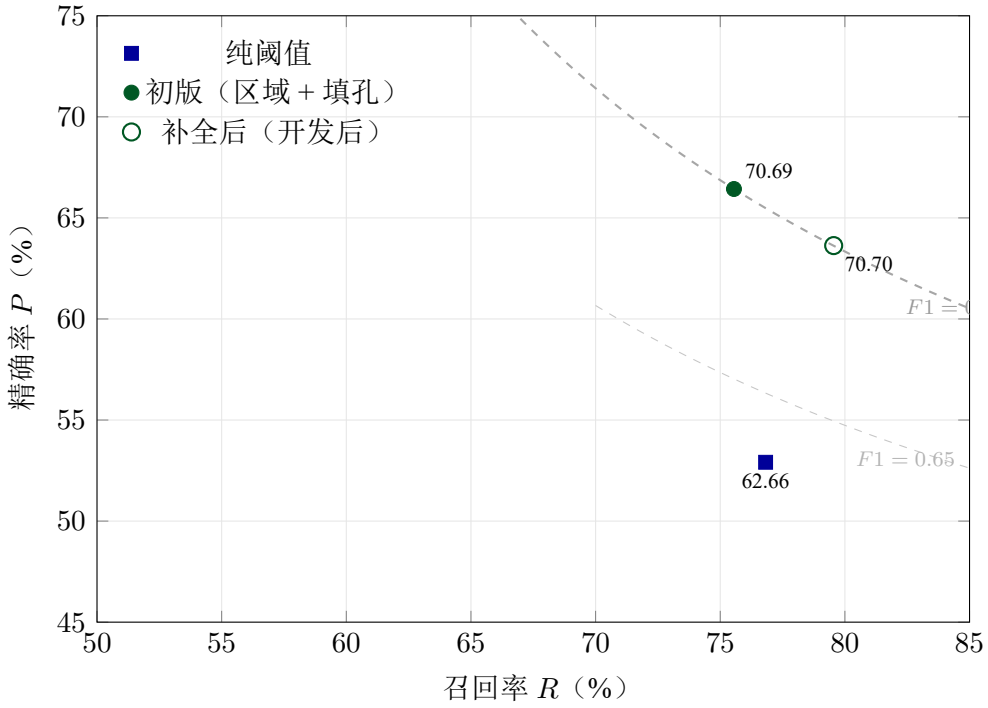


图 10: 三种方案在测试集上的精确率—召回率位置。实心点为独立测试，空心点为开发后对比；虚线为 F1 等值线。

这张图说明，补全没有让模型“更准”，只是把判决边界向外推了一圈：被包进来的像素中只有 35.45% 是脸。初版与补全后之间的选择，不是“哪个方法更好”，而是“愿意用多少精确率换多少召回”。

6.3 有效性的来源

从结果分布看，32 张测试图的初版 F1 并不呈连续分布。不低于 0.85 的有 11 张，其中 4 张超过 0.92；低于 0.2 的有 5 张；0.2 至 0.5 之间没有样本。补全后这个形状基本不变：11 张不低于 0.85，5 张低于 0.2，只有个别图像跨过区间边界。方法在多数图像上表现较好，在少数图像上几乎完全失败，中间状态很少。

在我们看来，这种两段式分布与第 6.1 节的结构假设一致。当脸部构成画面中占主导的肤色连通区域时，三个先验同时成立：颜色候选接近完整，最大连通域不会选错，填孔也能补回被包围的五官。当这一条件不成立时，错误会沿同一条链条被放大，而不是表现为分数的平缓下降。当前样本只有 32 张，这一形态也可能带有偶然性；但它至少提示，方法的成败更接近“条件是否满足”，而非“参数是否精细”。

在满足条件的图像上，方法的表现相当稳定。样本 00610 的原始候选为 80,328 像素，最大连通域保留 79,899 像素，填孔补回 9,490 个正确像素，最终 F1 为 0.930，召回率为 97.7%。00585、00629、00538 等图的情况类似。这些图像的一个共同特征是正面或近正面、脸部占画面比例较大、光照较均匀，头发与背景的颜色和肤色可分。对这些图像，颜色候选本身已接近完整，后处理只需少量修补。

方法的第二个优势体现在对五官的补偿上。颜色规则本来不覆盖眼睛、眉毛和嘴部，但填孔把这一组的召回率从 32.6% 提高到 68.3%，补回 69,662 个正确像素；皮肤与鼻子组也从 66.4% 提高到 76.3%。这说明“脸是一个被肤色包围的连通区域”这一先验在实际图像中相当强。方法并不区分这些像素的语义类别，只是利用了它们被脸部轮廓包围这一拓扑事实。就本实验的目标而言，这一补偿是有效的；但它也解释了补偿的上限：只有被完整包围的区域才能被补回。

第三个优势是可解释与可复现。方法只有四个统计参数和一个整数 k，没有随机初始化，也没有在测试阶段重新估计任何量。每一次失败都可以定位到颜色候选、区域选择或填孔中的某一步：00609 的错误始于颜色候选，00718 的错误始于区域选择，00676 的误差则在填孔阶段被放大。这种可归因性使讨论不必停留在“效果不好”，而可以具体到“哪一条先验没有成立”。此外，方法不需要训练，单张图像只经历一次颜色变换和两次连通域操作，结构上比需要训练的方法轻。

6.4 失效的来源

方法的失效可以按来源分为四类：颜色、空间、语义，以及评价口径。前三类属于方法本身，第四类属于我们如何定义对错。表 15 给出摘要。

表 15: 失效的四类来源

来源	不成立的假设	主要证据	调参能否解决
颜色	肤色落在训练矩形内	00609：候选 5,685 像素、56 块、召回 1.6%；低亮度组 F1 下降 3.8 个百分点	部分缓解，误检会回升
空间	存在占主导的脸部连通块	00718：最大块 58,716 像素，TP 仅 2,705；脖子占误检 23.4%	需更换区域评分
语义	肤色像素都属于脸	脖子与双耳 37.4 万像素；精确率上限约 85%	不能
评价	整脸真值与候选边界一致	逐图 Mask IoU 0.572，Boundary IoU 0.233	不能，属定义问题

颜色层。当图像存在明显偏色或照度不足时，真实肤色的色度会偏离训练分布，$k = 1.25$ 的矩形随之把大量正确像素排除在外。00609 是典型：$k = 1.25$ 下只剩 5,685 个候选像素，分成 56 个连通块，最大块 1,063 像素，最终召回率 1.6%。亮度分组的结果与此一致：较低亮度组的初版 F1 为 52.8%，比基线低 3.8 个百分点，正确像素减少约 9.6 万，漏检增加约 9.6 万。补全对这类图几乎没有作用：00609 的召回只从 1.59% 到 1.78%。需要说明，亮度分组是事后按真值区域平均 Y 划分的，只有 11 张图，且亮度与场景、肤色、妆容混杂，因此这里只能说明低亮度条件下风险更高，不能把下降单独归因于亮度。

空间层。最大连通域假设画面中存在一个占主导地位的脸部候选。当与肤色相近的头发形成更大连通块时，这一假设直接失效。00718 中，棕色头发构成 58,716 像素的最大块，其中正确像素只有 2,705 个，误检 56,011 个；填孔随后又增加 110 个正确像素和 10,871 个误检像素，最终 F1 为 0.045。补全把召回从 5.12% 推到 9.78%，仍然无济于事；00578 中，补全甚至沿着头发继续扩张，新增 22,692 个误检像素。这个例子说明，面积只能表示区域大小，不能表示区域属于什么。类似地，脖子与脸部通常连成同一块，无法通过连通性切开；在最终误检中，头发与脖子合计占 84.0%，其中脖子单独占 23.4%。

语义层。这是方法的真正上限。耳朵和脖子本身也是皮肤，颜色规则没有理由排除它们。测试集中，脖子与双耳合计约 37.4 万像素，占全部有效像素的 4.5%，而脸部正类约 215 万像素。即使颜色判决完全正确、不再产生任何头发或背景误检，只要结构仍是“最大连通域加填孔”，这部分像素仍会被计入前景，精确率的上限约为 85%。当前初版的精确率为 66.4%，与这一上限之间还有约 19 个百分点，说明头发与背景误检仍是主要矛盾；但即使把这些误检全部消除，纯颜色模型也无法达到更高的精确率。这一计算建立在“所有肤色像素都被判为正类”的假设上，实际方法可能因连通性排除部分耳朵，因此 85% 是量级上的上限，而非严格界。它的意义在于指出：剩余误差中有一部分不是参数问题，而是“颜色”这一信息本身不包含“脸”这一语义。

评价口径。还有一层不确定性来自评价本身。整脸真值与颜色候选之间的错位是任务定义的一部分：眼睛、眉毛和嘴部被计入正类，却不参与颜色建模。边界质量也受到这一错位的影响。初版方案的逐图 Mask IoU 平均为 0.572，而 Boundary IoU 平均仅为 0.233；前者说明区域大体重合，后者说明轮廓并不可信。填孔产生的是由外围轮廓决定的平滑边界，而不是真实的发际线或下颌线；标注本身在这些位置也存在歧义。因此，本方法适合给出粗略区域，不适合用于需要精确边缘的场合。

6.5 适用条件

把上述结果整理成条件，可以得到一个相对清晰的适用范围。这些条件来自 32 张测试图的观察，属于经验总结，不是经过独立验证的判据。表 16 给出摘要。

表 16: 适用条件与实验依据

场景条件	实验观察	判断
单人、近正面、脸部占比较大、光照均匀	11 张 F1 不低于 0.85，4 张超过 0.92	适用
偏色或照度不足	00609 F1 为 0.031；低亮度组下降 3.8 个百分点	风险高，需预处理
头发或背景与肤色接近	头发占误检 60.6%；00718 F1 为 0.045	易失效
脸与脖子相连	脖子占误检 23.4%	精度受限
多人、侧脸、遮挡	本数据未覆盖	未验证，不宜外推
需要精确边缘	Boundary IoU 0.233	不适用

据此，我们把适用场景限定为：单人、正面或近正面、脸部在画面中占较大比例、光照较均匀且与背景有较明显色差的图像；任务应是粗粒度区域提取或前置筛选，而不是精确边缘。多人、侧脸、遮挡等情形在本数据中没有覆盖，我们不把它们列入适用范围，也不据此判断方法在那些情形下的表现。概括而言，这套方法是一个在受控条件下可用的肤色先验，其适用范围主要由拍摄条件决定，参数调节只能在其内部微调。

如果必须在初版与补全后之间选一个，判断依据不是 F1，而是任务更在意什么。以 F1 和边界为准，选初版；以覆盖完整为准，选补全后。两者的 F1 相同，差别在精确率与召回的分配；这也是第 5 章反复出现的“工作点”一词的实际含义。

6.6 与其他颜色方法的关系

最后，把本方法放回颜色分割的谱系中，可以更清楚地看出它的位置。

基于 RGB 的规则更简单，但三个通道都混有亮度信息，阈值同时受光照强度与颜色影响；Cr/Cb 把亮度分离出去，代价是丢弃了 Y 中的明暗线索。本实验没有直接比较两者，00609 的结果只能说明色度通道同样会受白平衡影响，不能说明 RGB 规则一定更差。HSV 的色调对光照变化相对稳健，但皮肤通常落在低饱和区域，色调在低饱和时并不稳定。

训练分布本身还提供了另一条线索。Cr 与 Cb 的相关系数约为 -0.76，联合分布呈倾斜的椭圆，而当前判决使用的是轴对齐矩形。矩形的四个角会包含肤色分布之外的取值组合，而倾斜方向上的肤色又可能被矩形的边切掉。若改用马氏距离或椭圆边界，不必更换颜色空间，只需在现有均值、标准差之外增加一个相关系数，把“各通道独立”的假设换成“两通道联合”的假设。就我们看到的分布形态而言，这是改动最小、针对性最直接的一处。本实验没有实现这一方案，因此不能给出它可能带来的提升；这里只把它作为由数据直接支持的一个判断记录下来。

逐图自适应阈值是另一种常见思路。它可以根据每张图的色度分布重新确定范围，对偏色更稳健；但在本任务中，背景中的木质墙面、暖色衣物同样会形成大面积色度聚

集，自适应阈值有可能把这些区域纳入候选，与最大连通域的假设冲突。是否采用，取决于场景中是否存在稳定的肤色参照，而不能只按“能否适应光照”来判断。

至于基于学习的分割方法，它们能够利用形状、纹理和语义信息，理论上可以越过语义层的限制。但这类方法需要标注数据与训练过程，其结果也不再能简单归因到“颜色范围是否合适”。对于本实验提出的问题——颜色本身能走多远——引入学习模型后，这一问题就不再被回答。因此，我们选择在颜色框架内把边界刻画清楚，而不是用更强的模型换取更高的分数。

6.7 小结

本章的结论可以概括为一句话：这套方法的精度上限由它看不见的信息决定，而不是由 k 或核大小决定。颜色先验、单主体先验和闭合轮廓先验在受控条件下同时成立，方法就能达到 0.9 左右；其中任何一条不成立，误差就会沿流程被放大，而不是被后处理吸收。参数调整只能改变三条先验的松紧，不能补上它们缺少的形状与语义。就本实验而言，它的价值主要在于实现代价低、结果可解释、失败可归因，而不在精度上限。

7 结论与反思

本实验从 162 张带像素级标签的图像出发，完成了一次颜色分割的完整流程：训练集估计肤色统计，验证集选择阈值与后处理，测试集评价固定方案；随后针对测试暴露的内部缺口，做了补全尝试并再次评价。三个问题现在可以分别回答。

第一，这批人脸的肤色在 Cr/Cb 上确实存在集中区域。两通道标准差都约为 9.4，相关系数约为 -0.76，均值与标准差可以概括主要分布。但 $k = 1.25$ 只覆盖训练肤色的一部分，它不是一个完整的“肤色范围”，而是一个偏精确率的切片；这既解释了初版召回为什么上不去，也解释了低亮度图像为什么一收紧就掉得厉害。

第二，只靠颜色加两个空间规则，独立测试的 F1 为 70.69%，IoU 为 54.67%，比纯阈值基线提高 8.03 和 9.04 个百分点。提升主要来自减少误检：FP 减少 649,225，FN 只增加 27,409。阶段分解显示，k 收紧、最大连通域和填孔的交换率分别为 1:1.6、1:8.3 和 3.3:1；初版把颜色候选修剪得更干净，但没有增加新的判别信息。

第三，方法的边界由语义决定，而不是由阈值或核大小决定。头发与脖子合计占最终误检的 84.0%；耳朵和脖子本身就是皮肤，即使颜色判决完全正确，精确率的上限也约为 85%；低亮度组的 F1 反而下降 3.8 个百分点。补全尝试把召回提高 4.00 个百分点、精确率降低 2.80 个百分点，F1 基本不变；新增前景中只有 35.45% 是脸。形态学只能移动精确率—召回率工作点，不能补上缺失的语义。

这次实验也留下了三处设计上的遗憾。第一，补全的方向来自测试图 00570 的误差，虽然选核只用验证集，但测试样例已经参与了问题定义；同一批图对补全后的结果不再独立。第二，验证集被用了两次：第一次按 F1 选，第二次按“F1 损失不超过 1 个百分点、召回最大”选；两次规则都写在运行前，但规则的切换发生在看到第一轮结果之后，这会放大验证集的乐观偏差。第三，32 张验证图上比较了 36 组和 15 组候选，选参噪声不可忽略；验证 F1 72.70% 到测试 70.69% 的回落，幅度合理，但不能当作无偏估计。如

果重做，我们会把补全的动机留在验证集的失败图上，把召回优先的目标在第一次选参前写死，并为最终方案另留一批测试图。

这次实验最大的收获不是 70.69%。它让我们具体看到，颜色模型的价值和上限是同时存在的：在单人、近正面、光照较均匀、与背景色差明显的条件下，它可以用四个参数和两次连通域操作给出可用的粗区域；一旦离开这些条件，增加形态学、调整 k 都只是在工作点上移动。它的瓶颈不在参数，而在颜色本身不包含“这是脸”这一语义。

参考文献

[1] Hsu R L, Abdel-Mottaleb M, Jain A K. Face detection in color images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, 24(5): 696–706.

[2] Vezhnevets V, Sazonov V, Andreeva A. A survey on pixel-based skin color detection techniques[C]. Proceedings of GraphiCon, 2003: 85–92.

[3] Kovac J, Peer P, Solina F. Human skin color clustering for face detection[C]. Proceedings of IEEE EUROCON, 2003, 2: 144–148.

[4] Cheng B, Girshick R, Dollár P, et al. Boundary IoU: Improving object-centric image segmentation evaluation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 15334–15342.